LAPORAN PROJECT DATA ANALYSIS

Studi Komparatif Algoritma K-Means dan DBSCAN Dalam Clustering Paling Optimal pada Dataset Gempa Bumi

Disusun Oleh :

Evelyn Gracia (00000108299)

Kelvinia (00000110164)

Valerie Kurniawan (00000108382)

Program Studi: Information System

Mata Kuliah:

IS388 - Data Analysis

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS TEKNIK DAN INFORMATIKA

UNIVERSITAS MULTIMEDIA NUSANTARA

SEMESTER GANJIL 2025-2026

ABSTRAK

Penelitian ini bertujuan untuk melakukan studi komparatif guna menentukan algoritma clustering yang paling optimal dalam mengidentifikasi pola geospasial gempa bumi, dengan membandingkan kinerja K-Means dan DBSCAN. Dataset gempa bumi hanya menggunakan variabel *latitude* dan *longitude* untuk menentukan zona aktivitas seismik. Evaluasi model dilakukan menggunakan metrik *Silhouette Score* untuk mengetahui kualitas dari cluster yang terbentuk. Hasil menunjukkan bahwa DBSCAN menghasilkan *Silhouette Score* tertinggi dibandingkan K-Means. DBSCAN sebagai algoritma yang paling optimal karena mampu menangani data geospasial yang memiliki pola penyebaran kompleks, tidak teratur, dan bervariasi berdasarkan kepadatan.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas berkat rahmat dan anugerah-Nya, laporan dengan judul **"Studi Komparatif Algoritma K-Means dan DBSCAN Dalam Clustering Paling Optimal pada Dataset Gempa Bumi"** dapat terselesaikan dengan baik. Kami juga menyampaikan terima kasih kepada dosen pengampu, pembimbing, serta rekan-rekan yang telah memberikan dukungan, arahan, dan motivasi selama proses penyusunan laporan ini.

Laporan ini berisi analisis komparatif terhadap 2 algoritma clustering, yaitu K-Means dan DBSCAN, yang diterapkan pada dataset gempa bumi Indonesia. Penelitian ini disusun dengan tujuan untuk mengidentifikasi algoritma yang paling optimal dalam mengelompokkan pola gempa bumi berdasarkan pendekatan *unsupervised learning*. Harapannya, hasil penelitian ini dapat memberikan kontribusi dalam bidang analisis data seismik serta menjadi referensi dalam pemilihan metode clustering pada data kebencanaan.

Kami menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, dengan rendah hati kami memohon maaf apabila terdapat kekurangan di dalamnya. Kami sangat terbuka dan menerima kritik serta saran yang membangun demi perbaikan dan penyempurnaan karya di masa mendatang.

Minggu, 16 November 2025

Kelompok 2

DAFTAR ISI

ABSTRAK **2**
KATA PENGANTAR **3**
DAFTAR ISI **4**
BAB I BUSINESS UNDERSTANDING **5**
1.1 Latar Belakang 5
1.2 Clustering 7
1.2.1 Pengertian Clustering 7
1.2.2 Jenis Algoritma Clustering 7
1.3 Rumusan Masalah 8
1.4 Tujuan Penelitian 8
1.5 Manfaat Penelitian 9
1.6 Penelitian Terdahulu 10
BAB II DATA UNDERSTANDING **12**
2.1 Dataset 12
2.1.1 Sumber Dataset 12
2.1.2 Deskripsi Dataset 12
2.1.3 Deskripsi Variabel 13
2.2 Struktur Data 14
2.3 Kualitas Data 15
2.3.1 Pengecekan Missing Value 15
2.3.2 Pengecekan Duplikasi Data 15
2.3.3 Pengecekan Outlier 16
2.3.4 Distribusi Lokasi Gempa 16
2.3.5 Histogram Latitude 17
2.3.5 Histogram Longitude 18
BAB III DATA PREPARATION **20**
3.1 Dataset Reduction (Sampling) 20
3.2 Normalization 20
BAB IV MODELLING **22**
4.1 K-Means 22
4.2 DBSCAN 24
BAB V EVALUATION **26**
BAB VI DEPLOYMENT **27**
BAB VII HASIL DAN PEMBAHASAN **30**
BAB VII KESIMPULAN **31**
REFERENSI **32**

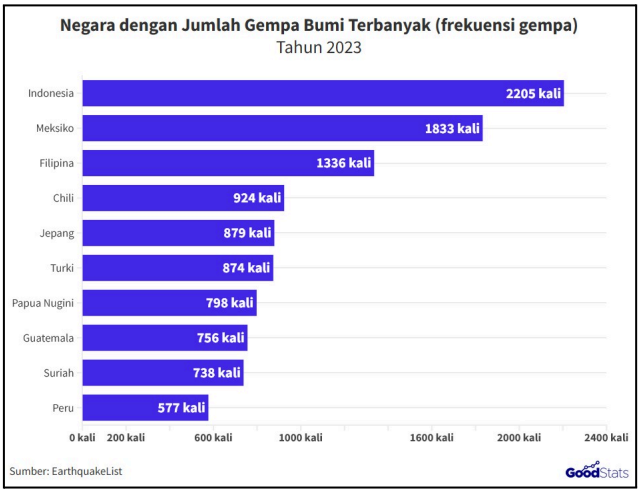
BAB I
BUSINESS UNDERSTANDING

Business Understanding merupakan tahapan pertama dalam CRISP-DM untuk memahami kebutuhan dan tujuan bisnis secara mendalam [2]. Pada tahap ini dilakukan dengan mencari identifikasi, penyebab, tujuan, dan dampak dari suatu permasalahan. Dengan memahami permasalahan yang sedang dianalisa, dapat mempermudah untuk mencapai hasil yang diinginkan dan tujuan dapat terealisasikan.

1.1 Latar Belakang

Gempa bumi merupakan salah satu fenomena alam yang terjadi akibat pelepasan energi di dalam kerak bumi sehingga menimbulkan getaran yang dapat dirasakan di permukaan [11]. Seberapa besar gempa yang terjadi dinyatakan dalam nilai magnitudo, sebagai indikator utama dalam menentukan tingkat kekuatan dan potensi kerusakan akibat gempa. Wilayah dengan aktivitas seismik tinggi berpotensi besar untuk mengalami kerugian material maupun korban jiwa. Maka dari itu, pemahaman terhadap pola kejadian gempa sangatlah penting sebagai upaya mitigasi bencana.

Badan Meteorologi Klimatologi dan Geofisika (BMKG) mencatat ribuan kejadian gempa setiap tahunnya, baik yang dirasakan maupun tidak [12]. Gempa bumi dapat terjadi tanpa prediksi yang jelas dan tepat, sehingga ketidaksiapan warga dalam menyelamatkan nyawanya dan juga dipengaruhi oleh faktor kurangnya pengetahuan mengenai aktivitas gempa di lingkungannya. Oleh karena itu, diperlukan informasi aktivitas seismik berdasarkan tingkat kekuatan, frekuensi, dan lokasi kejadian dalam pemahaman pola sebaran gempa.



Gambar 1.1 Data Kejadian Gempa Bumi Tahun 2023

Hal ini juga selaras dengan nilai *Sustainable Development Goals (SDGs)*, yang dimana dengan adanya analisis pola kejadian gempa yang akurat dapat memberikan kontribusi langsung pada pencapaian, seperti:

- **SDG 11 (*Sustainable Cities and Communities*)**, bahwa pentingnya peningkatan ketahanan kota dan permukiman terhadap bencana. Maka dari itu, dengan adanya pemahaman mengenai wilayah mana yang memiliki aktivitas seismik tinggi, pemerintah dapat mengambil keputusan yang tepat dan strategis untuk upaya mitigasi seperti penempatan tata letak perumahan ataupun infrastruktur lainnya.
- **SDG 13 (*Climate Action*)**, bahwa pentingnya peningkatan kapasitas adaptasi dan pengurangan risiko bencana. Dengan adanya data tersebut, dapat memperkuat sistem peringatan dini dan membantu pengambilan keputusan bagi pihak yang berwenang dan juga warga untuk antisipasi.

Dengan adanya penelitian dalam membandingkan performa antara kedua algoritma tersebut dalam mengelompokkan data gempa bumi dan berharap dapat memberikan rekomendasi algoritma yang paling optimal, sehingga dapat diterapkan dalam analisis risiko gempa sekaligus mendukung perencanaan kebijakan mitigasi bencana berbasis data.

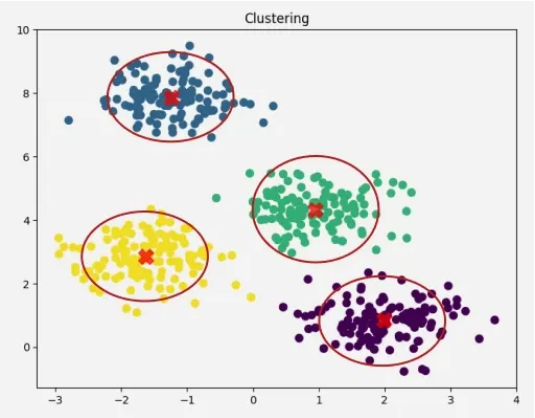
Seiring dengan perkembangan jumlah data gempa yang tersedia, penerapan teknik data mining menjadi relevan untuk membantu mengolah data dalam jumlah besar secara efektif. Data mining berperan penting dalam mengekstraksi pola dan informasi dari data berskala besar, terutama data yang kompleks dan memiliki banyak variabel [5]. Teknik ini mampu untuk menghasilkan *insight* yang tidak terlihat secara langsung dari data mentah, sehingga sangat relevan untuk diterapkan pada data gempa bumi yang bersifat multidimensional seperti magnitudo, kedalaman, waktu kejadian, dan lokasinya.

Dalam konteks mitigasi bencana, penerapan clustering sebagai *unsupervised learning* dapat membentuk mengelompokkan wilayah kejadian gempa berdasarkan tingkat aktivitas seismik yang dapat digunakan sebagai dasar dalam menentukan prioritas wilayah yang rawan gempa dan strategi mitigasi agar dampak bencana dapat diminimalkan. Pemilihan algoritma clustering sangatlah krusial, karena setiap algoritma memiliki performa yang berbeda-beda sesuai karakteristik dataset, sehingga diperlukan penelitian yang komparatif untuk menentukan mana algoritma yang paling akurat dalam menganalisis data gempa bumi.

1.2 Clustering

1.2.1 Pengertian Clustering

Clustering merupakan salah satu metode dalam *machine learning* untuk mengelompokkan sejumlah data ke dalam kelompok-kelompok berdasarkan kesamaan tertentu. Hal ini cocok untuk data yang tidak memiliki label, sehingga setiap objek dijadikan menjadi 1 kelompok dengan karakteristik yang mirip satu sama lain dibandingkan dengan objek di kelompok lain [7].



Gambar 1.1 Clustering (Sumber: GeeksforGeeks)

1.2.2 Jenis Algoritma Clustering

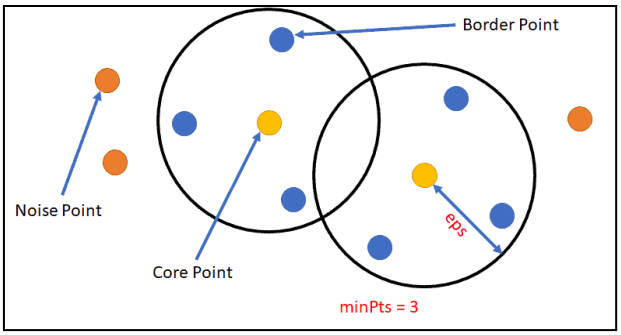
Clustering dapat dilakukan dengan menggunakan berbagai algoritma untuk mengelompokkan data berdasarkan karakteristik tertentu. Setiap algoritma memiliki pendekatan mekanisme yang berbeda dalam menentukan *cluster*, sehingga pemilihan metode harus disesuaikan dengan jenis data dan tujuan analisis. Beberapa jenis algoritma *clustering* yang umum digunakan adalah sebagai berikut.

1. **K-Means Clustering**

   K-Means Clustering merupakan salah satu algoritma clustering yang bekerja dengan membagi data ke dalam sejumlah cluster K berdasarkan kedekatan setiap data terhadap *centroid* cluster. Proses K-Means dimulai dengan memilih K *centroid* awal secara acak, kemudian setiap data diberikan label sesuai dengan *centroid* terdekat. Kelebihan dari algoritma K-Means terdapat pada kecepatan dan kesederhanaan, sedangkan kelemahannya adalah sensitif terhadap pemilihan centroid awal dan keberadaan *outlier* [7].

2. **DBSCAN (*Density-Based Spatial Clustering of Application with Noise*) Clustering**

DBSCAN merupakan algoritma yang membentuk sebuah cluster berdasarkan kepadatan. Cara kerja DBSCAN dengan parameter epsilon sebagai radius pencarian untuk menentukan seberapa jauh dekatnya antar titik dan minPts sebagai jumlah minimum titik untuk bisa dijadikan sebuah cluster. Titik-titik dalam suatu area yang memiliki tetangga cukup banyak disebut dengan *core poin*t, sebaliknya dengan titik - titik yang tidak memenuhi syarat densitas disebut dengan *noise* atau *outlier* [8].



Gambar 1.2 DBSCAN Clustering (Sumber: Machine Learning Geek)

1.3 Rumusan Masalah

Berdasarkan latar belakang di atas, adapun beberapa masalah yang telah dirumuskan sebagai berikut.

1. Bagaimana proses penerapan algoritma K-Means dan DBSCAN pada dataset gempa bumi?
2. Algoritma clustering manakah yang paling sesuai untuk mengelompokkan pola geospasial bencana gempa bumi berdasarkan parameter *latitude* dan *longitude*?
3. Bagaimana kemampuan algoritma K-Means dan DBSCAN dalam menangani dataset gempa bumi berukuran besar?

1.4 Tujuan Penelitian

Berdasarkan permasalahan yang telah dirumuskan, berikut merupakan tujuan penelitianya.

1. Untuk mengetahui proses penerapan algoritma K-Means dan DBSCAN pada dataset gempa bumi.
2. Untuk mengetahui perbandingan efektivitas algoritma K-Means dan DBSCAN dalam mengelompokkan pola geospasial bencana gempa bumi berdasarkan parameter *latitude* dan *longitude*.

3. Untuk bahan evaluasi kemampuan K-Means dan DBSCAN dalam menangani dataset gempa bumi berukuran besar.

1.5 Manfaat Penelitian

Hasil penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

a) Manfaat Teoritis
   - Memberikan kontribusi dalam pengembangan ilmu pengetahuan terkait penerapan algoritma clustering pada data gempa bumi.
   - Menjadi referensi bagi peneliti lain dalam pemilihan algoritma clustering yang sesuai dengan karakteristik data geofisika.

b) Manfaat Praktis
   - Memberikan rekomendasi algoritma terbaik yang dapat digunakan untuk analisis risiko gempa.
   - Mendukung lembaga seperti BMKG dan instansi kebencanaan dalam mengelompokkan wilayah rawan gempa berbasis data.
   - Menjadi dasar pertimbangan dalam perencanaan mitigasi bencana dan penyusunan prioritas penanganan daerah berpotensi tinggi.

1.6 Penelitian Terdahulu

No	Judul	Algoritma	Variable	Hasil (Silhoutte Score)	Kesimpulan
1	Clustering Gempabumi di Wilayah Regional VII (Arafat, 2023)	DBSCAN K-Means	Latitude Longitude 1.827 data	K-Means (Euclidean): 0,570 DBSCAN (Euclidean): 0,486	DBSCAN (terbaik secara geologi/kemiripan peta) vs K-Means (terbaik secara metrik Silhouette)
2	Pengelompokan Data Gempa Bumi Menggunakan Algoritma DBSCAN (Rahman & Wijayanto, 2021)	DBSCAN OPTICS	Latitude Longitude Depth Magnitude 35.792 data	DBSCAN: 0.81091 OPTICS: 0.58126	DBSCAN mampu mengelompokkan wilayah berisiko gempa bumi dengan cukup baik
3	Implementation of DBSCAN for Earthquake Clustering in Indonesia (Hafid et al., 2025)	DBSCAN	Magnitude Depth 1.267 data	0,3959	DBSCAN sangat cocok untuk data gempa bumi yang mampu mengidentifikasi klaster dengan bentuk bebas (free-form) dan tidak teratur, dan otomatis mendeteksi noise, yang sering ditemui pada distribusi data gempa
4	A Comparative Analysis of DBSCAN, K-Means and Agglomerative (Jain et al., 2025)	DBSCAN K-Means Agglomerative	Data Geospatial 600 data	DBSCAN: 0.8646 K-Means: 0.8160 Agglomerative: 0.8160	DBSCAN unggul dalam robustness (ketahanan) dan mengidentifikasi cluster dengan bentuk tidak beraturan dan kemampuannya menangani noise dengan baik, yang merupakan karakteristik umum data spasial/geospasial
5	An Approach for Clustering of Seismic Events (Karmenova et al., 2022)	DBSCAN	Latitude Longitude 1.668 data	Evaluasi tidak berdasarkan metrik, melainkan analisis kepadatan visual cluster	DBSCAN optimal dalam mengidentifikasi batas-batas cluster yang mewakili zona patahan (yang seringkali tidak berbentuk bulat/elips seperti asumsi K-Means) dan efisien dalam memfilter data noise

Berdasarkan penelitian terdahulu mengenai clustering data gempa bumi, menyatakan bahwa algoritma DBSCAN unggul dalam mengolah data spasial yang tidak terdistribusi secara seragam, seperti data seismik [26], [27], [28]. Berbeda dengan halnya dari penelitian oleh Arafat (2023), yang menggunakan variabel *longitude* dan *latitude* pada 1.827 data gempa bumi menemukan bahwa K-Means menghasilkan *silhouette score* yang lebih tinggi

(0,570) dibandingkan DBSCAN (0,486) [24]. Walaupun, penelitian tersebut menyimpulkan bahwa DBSCAN secara kualitatif lebih optimal karena cluster yang dibentuk lebih akurat dalam merepresentasikan peta sebaran gempa bumi secara geologis.

Ambiguitas ini kontras dengan mayoritas penelitian terdahulu oleh Jain et al (2025), Karmenova et al (2022), dan Rahman & Wijayanto (2021) yang menyatakan DBSCAN lebih optimal dan telah dibuktikan dengan Silhouette Score tinggi hingga 0,8646 [28] dan 0,81091 [2].

Oleh karena itu, penelitian ini berupaya menyelesaikan ambiguitas tersebut dengan menggunakan *longitude*, *latitude* dan 1.827 data gempa bumi, seperti penelitian Arafat (2023). Hal ini bertujuan untuk membuktikan bahwa DBSCAN tidak hanya unggul dari segi interpretasi geologis, tetapi juga dapat mencapai *Silhouette Score* yang lebih tinggi dan lebih optimal dibandingkan K-Means, sehingga sejalan dengan temuan pada penelitian terdahulu lainnya.

BAB II
DATA UNDERSTANDING

Data understanding merupakan tahapan yang bertujuan untuk memahami karakteristik data. Pada tahap ini dilakukan kegiatan berupa mengumpulkan, mengidentifikasi, menganalisis kumpulan data dan memverifikasi kualitas data yang dapat membantu untuk mencapai tujuan proyek [2]. Tahapan data understanding merupakan tahapan penting agar peneliti dapat memahami karakteristik dataset sebelum masuk ke dalam tahapan data preparation dan pemodelan lebih lanjut.

Dataset yang digunakan dalam penelitian ini merupakan data gempa bumi dari USGS (*United States Geological Survey*), yang diperoleh dari *Kaggle*. Dataset tersebut berisi data-data seismik yang mencakup berbagai variabel, seperti *latitude, longitude, depth, magnitude*, dan parameter seismik lainnya. Analisis eksplorasi akan dilakukan untuk memahami distribusi data dan mendeteksi data yang tidak wajar.

Untuk dapat melakukan proses *clustering* secara optimal, perlu dipahami terlebih dahulu dataset yang dimiliki dengan identifikasi sumber rincian variabel yang tersedia. Hal ini bertujuan untuk memastikan bahwa *dataset* sesuai sebelum memasuki tahap *Exploratory Data Analysis (EDA)* untuk memahami pola awal, distribusi, dan karakteristik utama dari data gempa bumi.

2.1 Dataset

2.1.1 Sumber Dataset

Dataset yang digunakan dalam penelitian ini merupakan dataset gempa bumi yang diperoleh dari platform *Kaggle*. *Kaggle* merupakan salah satu repositori data publik yang banyak digunakan dalam bidang *data science* karena menyediakan berbagai dataset yang telah dikurasi serta siap digunakan untuk keperluan analisis maupun pemodelan.

2.1.2 Deskripsi Dataset

Dataset yang digunakan adalah usgs.csv, yang berisikan kumpulan data aktivitas seismik yang diperoleh dari *United States Geological Survey (USGS)* yang memberikan informasi tentang gempa bumi yang terjadi di wilayah Amerika Serikat

dan sekitarnya dilengkapi dengan waktu kejadian, lokasi geografis (lintang–bujur), kedalaman gempa, magnitudo, dan parameter seismik lainnya

Dataset ini cocok untuk dilakukannya proses clustering yang menggunakan metode *unsupervised learning*. Melalui pendekatan ini, pola di dalam data dapat diidentifikasi tanpa perlu melakukan labeling. Lalu, model dapat menemukan pola pola persebaran gempa berdasarkan lintang dan bujur.

2.1.3 Deskripsi Variabel

Dataset usgs.csv terdiri dari beberapa variabel atau kolom, yang masing-masing mengandung informasi spesifik terkait objek penelitian. Variabel-variabel yang terdapat dalam dataset usgs.csv ini dijelaskan sebagai berikut.

Tabel 2.1 Deskripsi Variabel

No.	Nama Variabel	Tipe Data	Deskripsi
1	time	DateTime	Waktu terjadinya gempa bumi
2	latitude	Float	Garis lintang lokasi gempa
3	longitude	Float	Garis bujur lokasi gempa
4	depth	Float	Kedalaman pusat gempa (km)
5	mag	Float	Magnitudo gempa
6	magType	String	Jenis metode pengukuran magnitudo
7	nst	Integer	Jumlah stasiun seismik yang digunakan untuk perhitungan magnitudo
8	gap	Float	Jarak sudut maksimum antara stasiun seismik
9	dmin	Float	Jarak ke stasiun terdekat

10	rms	String	Root-mean-square residu waktu gelombang seismik
11	net	String	Jaringan seismik yang mendeteksi gempa
12	updated	dateTime	Waktu berakhir data diperbaharui
13	place	String	Deskripsi lokasi kejadian
14	horizontalError	Float	Perkiraan kesalahan posisi horizontal
15	depthError	Float	Perkiraan kesalahan pengukuran kedalaman
16	magError	Float	Perkiraan kesalahan nilai magnitudo
17	MagNst	Integer	Jumlah stasiun yang dipakai untuk menghitung *magError*
18	status	String	Status peninjauan kejadian gempa
19	locationSource	String	Sumber penentuan lokasi gempa

2.2 Struktur Data

Dataset akan dibentuk dalam *Data Frame* untuk memudahkan proses eksplorasi dan analisis. Dataset tersebut memiliki 75.810 baris dan 22 kolom, yang dimana cukup besar sehingga memerlukan perhatian pada efisiensi komputasi saat melakukan proses clustering.

Pemeriksaan tipe data untuk memastikan apakah setiap kolom memiliki tipe yang sesuai. Dengan mengetahui tipe data sejak awal, dapat melanjutkan tahap berikutnya

untuk diproses dengan tepat pada tahap analisis. Diketahui pada kolom *latitude* dan *longitude* telah sesuai tipe data 'float' sehingga siap untuk melakukan perhitungan.

Dengan berbagai variabel dalam dataset tersebut, namun fokus dalam penelitian ini adalah mengetahui pola persebaran gempa bumi atau secara geospasial saja, maka hanya memerlukan variabel lintang dan bujur saja. Oleh sebab itu, diperlukannya proses pemilihan memilih subset fitur (variabel) yang paling relevan untuk meningkatkan akurasi dan efisiensi waktu [10], yaitu pemilihan fitur (*feature selection*) yang hanya menggunakan *latitude* dan *longitude* saja.

2.3 Kualitas Data

Pemeriksaan kualitas data dilakukan untuk memastikan dataset dapat digunakan untuk proses analisis dan pemodelan. Tahapan ini mencakup pengecekan keberadaan *missing value*, duplikasi dan *outlier.* Hal ini sangat penting untuk menampilkan model yang dapat menghasilkan hasil clustering yang lebih akurat.

2.3.1 Pengecekan *Missing Value*

Pengecekan *missing value* dilakukan untuk mengetahui apakah terdapat nilai kosong pada masing-masing variabel. Pada implementasi, proses ini dilakukan dengan fungsi isnull().sum() pada seluruh kolom dataset. Hasil pengukurannya menunjukkan bahwa tidak ada *missing value*.

```
latitude     0
longitude    0
```

Gambar 2.1 Hasil Pengecekan *Missing Value*

2.3.2 Pengecekan Duplikasi Data

Pengecekan duplikasi data dilakukan untuk mengidentifikasi apakah terdapat data yang tercatat lebih dari satu kali dengan nilai yang sama pada semua kolom. Hasil menunjukkan bahwa terdapat 734 berarti jumlah lokasi gempa yang muncul ulang di tempat yang sama persis.

Pada umumnya, jika ada nilai duplikasi maka perlu melakukan penghapusan. Namun, berbeda hal dengan konteks gempa bumi yang dimana sangat wajar bahwa adanya duplikasi karena gempa bisa terjadi berulang kali di lokasi yang sama. Oleh sebab itu, tidak perlu penghapusan duplikasi data pada fitur utama.

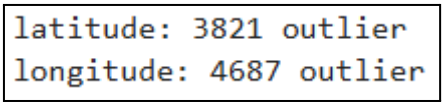


Gambar 2.2 Jumlah Duplikasi

2.3.3 Pengecekan *Outlier*

Pengecekan *outlier* dilakukan untuk mengetahui titik data yang berbeda secara signifikan dari data lainnya. Hal ini bertujuan untuk memahami pola persebaran gempa dan mendeteksi titik anomali geospasial. Namun, berbeda halnya dengan keputusan untuk geospasial gempa ini, yang dimana tidak perlu melakukan penghapusan outlier.

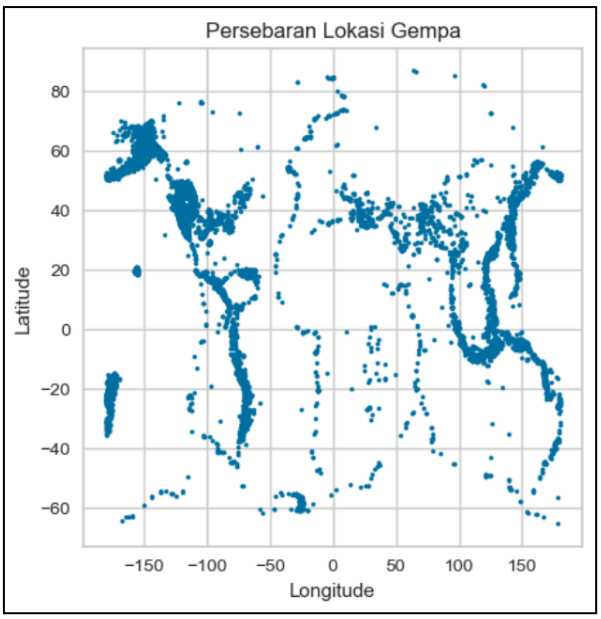
Dalam konteks geospasial gempa, yang dimana outlier justru merupakan informasi penting untuk mengetahui pola aktivitas seismik yang relevan dengan dunia nyata. Jika dihapuskan akan menghilangkan realitas alam.



Gambar 2.3 Jumlah *Outlier*

2.3.4 Distribusi Lokasi Gempa

Visualisasi distribusi lokasi gempa dilakukan untuk melihat pola distribusi lokasi gempa berdasarkan *latitude* dan *longitude*. Hasil visualisasi menunjukkan persebaran lokasi gempa berada pada latitude -60 hingga 80, dan longitude -150 hingga 150. Persebaran titik gempa tidak merata, titik paling banyak terjadinya gempa berada pada longitude -150 hingga -100 dan longitude 100 hingga 150 di wilayah Pesisir Barat Benua Amerika.

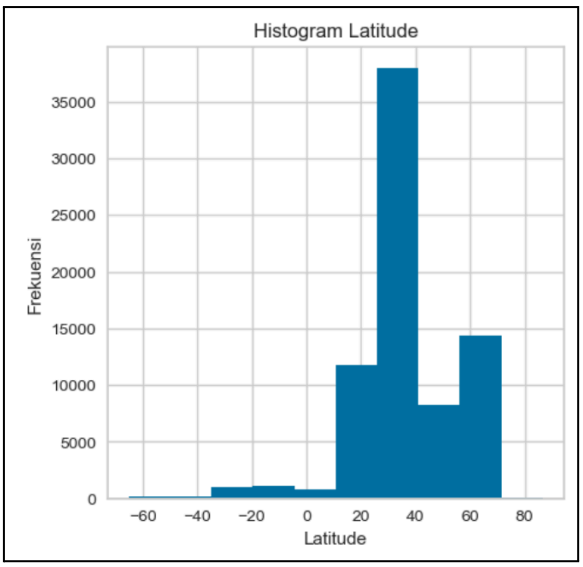


Gambar 2.4 Scatter Plot Persebaran Lokasi Gempa

2.3.5 Histogram Latitude

Latitude atau lintang merupakan garis horizontal yang mengukur jarak suatu titik ke utara atau selatan dari Garis Khatulistiwa (0°). Pada gambar 2.5 menunjukkan bahwa sebagian besar kejadian gempa bumi berada pada rentang sekitar 20° hingga 60° lintang di wilayah lintang menengah, terutama di sekitar jalur Ring of Fire di belahan utara. Sementara, frekuensi rendah di bawah −40° atau di atas 80°,menunjukkan bahwa kawasan kutub dan wilayah lintang jauh selatan jarang terjadi gempa.

Tanda	Arah	Nama Wilayah	Rentang Sudut
+	Utara dari Khatulistiwa	Lintang Utara (LU)	0° hingga 90°
-	Selatan dari Khatulistiwa	Lintang Selatan (LS)	0° hingga - 90°

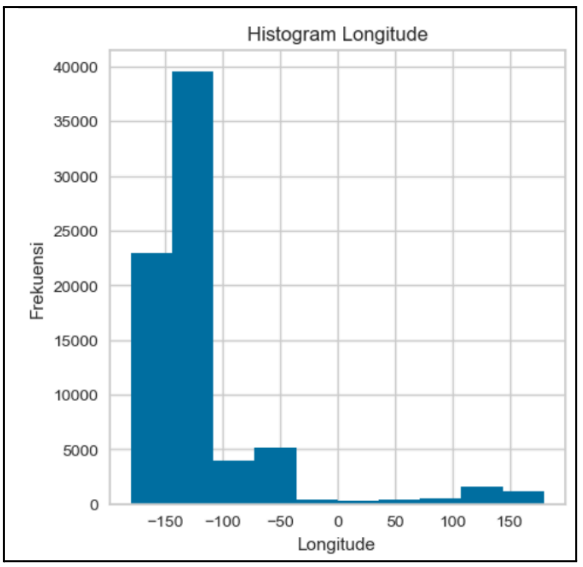


Gambar 2.5 Histogram Latitude

2.3.5 Histogram Longitude

Longitude atau bujur merupakan garis vertikal yang mengukur jarak suatu titik ke timur atau barat dari Meridian Utama. Pada gambar 2.6 menunjukkan bahwa gempa bumi paling banyak terjadi di sekitar −170° hingga −100° bujur, bagian wilayah Samudra Pasifik bagian timur, pantai barat Amerika Utara dan Selatan. Sementara frekuensi rendah dari 0° hingga 150° di wilayah Eropa, Afrika, dan sebagian Asia jarang terjadi gempa.

Tanda	Arah	Nama Wilayah	Rentang Sudut
+	Timur dari Meridian Utama	Bujur Timur (BT)	0° hingga 180°
-	Barat dari Meridian Utama	Bujur Barat (BB)	0° hingga - 180°



Gambar 2.6 Histogram Longitude

BAB III
DATA PREPARATION

Data preparation merupakan tahap untuk menyiapkan data yang akan digunakan pada proses pemodelan. *Preprocessing* data diperlukan untuk memastikan bahwa data telah sesuai agar dapat menghasilkan analisis yang tepat [22]. Pada penelitian ini, akan dilakukan data *reduction* dan proses normalisasi untuk menyamakan rentang nilai variabel *latitude* dan *longitude*.

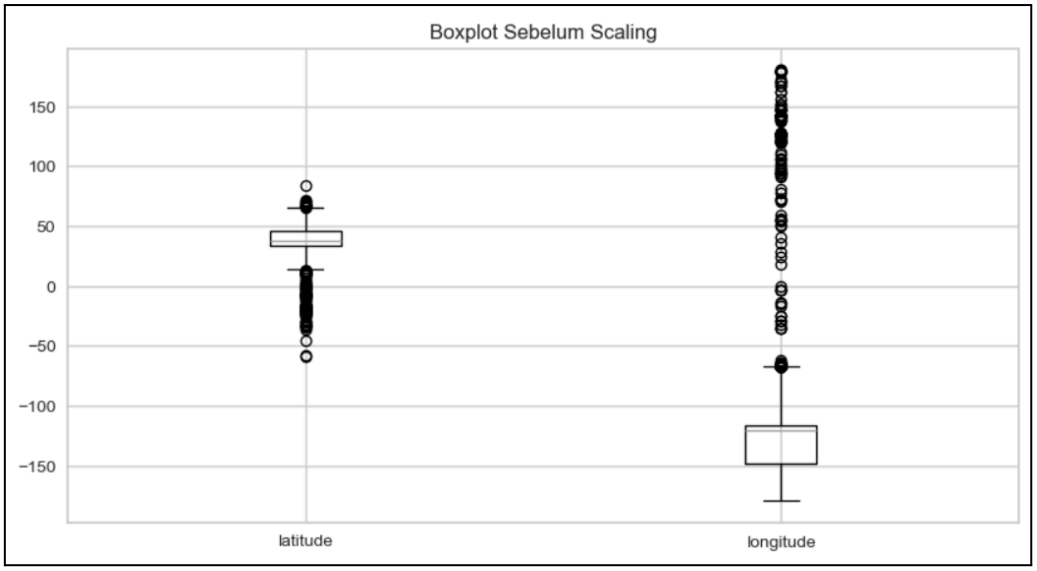
3.1 Dataset Reduction (Sampling)

Data reduction merupakan proses pengurangan *volume* data asli namun tetap mempresentasikannya dalam *volume* yang lebih kecil dengan tetap menjaga integritas data asli. Reduksi data dapat meningkatkan efisiensi penyimpanan dan mempermudah proses analisis sehingga performa algoritma *machine learning* meningkatkan dengan mengurangi ukuran kumpulan data [17].

Pada tahap analisis *clustering*, akan digunakan sampel sebanyak 1.827 data dari 75.810. Pemilihan jumlah sampel tersebut dilakukan untuk menjaga kinerja sistem dan menghindari beban komputasi berlebih. Selain itu, pemilihan sampel dilakukan secara acak dengan menetapkan *random_state*, sehingga seluruh distribusi data keseluruhan dan memungkinkan replikasi hasil penelitian tetap dapat terwakili.

3.2 Normalization

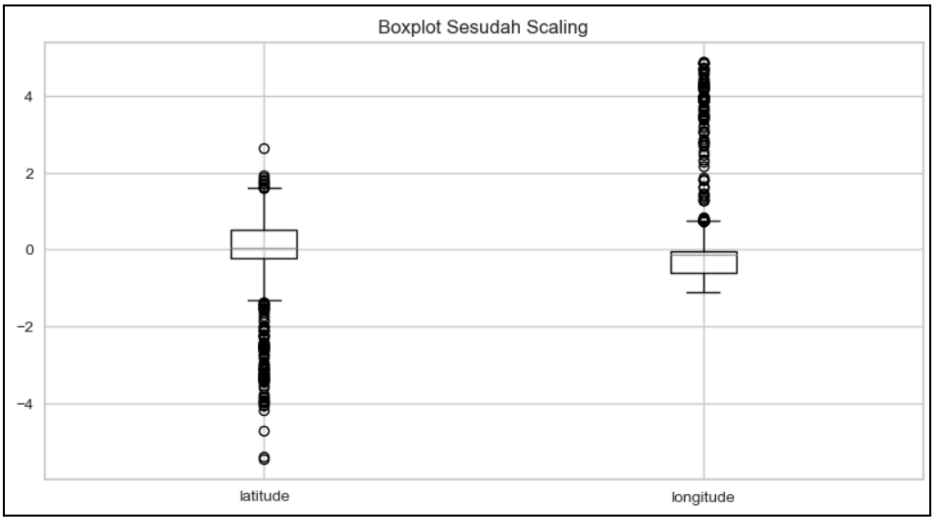
Normalisasi dilakukan dengan metode *Standard Scaler* untuk menyamakan skala pada variabel-variabel numerik agar tidak ada variabel yang mendominasi variabel lainnya pada proses pemodelan. Proses ini sangat penting, khususnya untuk metode K-Means, karena algoritma ini sangat sensitif terhadap skala antar fitur [16]. Standard Scaler dipilih karena dataset gempa memiliki nilai ekstrim dan tidak stabil, dimana setiap fitur akan diproses sehingga memiliki distribusi dengan rata-rata 0 dan simpangan baku 1 [23]. Berikut merupakan box plot dari variabel *latitude* dan *longitude* sebelum dilakukan normalisasi.



Gambar 3.1 Boxplot variabel *latitude* dan *longitude* sebelum normalisasi

Dapat dilihat bahwa data tersebut memiliki rentang nilai yang sangat luas dan terdapat sejumlah titik yang berperan sebagai *outlier*. Dalam kondisi ini, dapat diindikasikan bahwa kedua fitur tersebut memiliki skala yang berbeda dan berpotensi untuk menyebabkan model analisis atau *machine learning* menjadi *bias* terhadap fitur yang memiliki nilai lebih besar.

Selanjutnya, berikut adalah boxplot dari variabel *latitude* dan *longitude* sesudah dilakukan normalisasi.



Gambar 3.2 Boxplot variabel *latitude* dan *longitude* setelah normalisasi

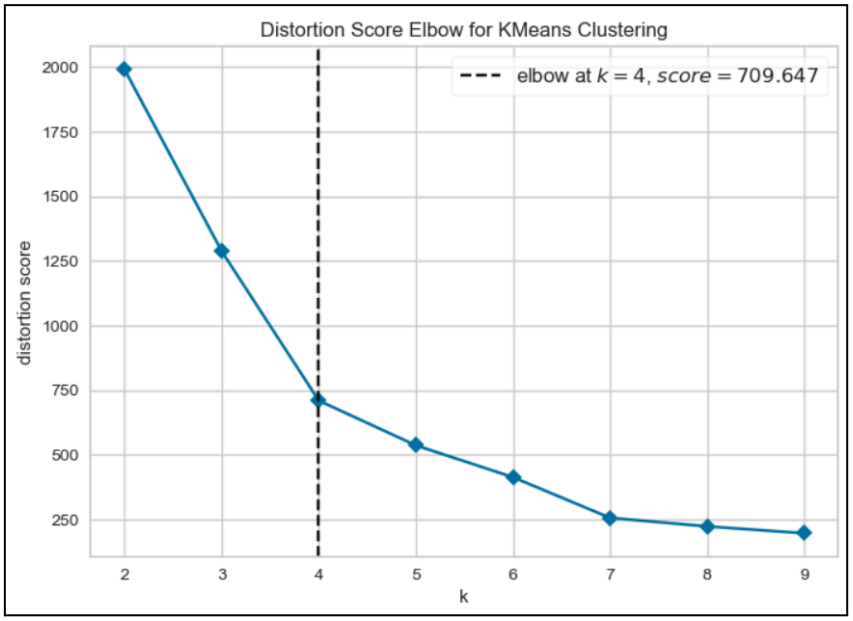
Dapat dilihat bahwa distribusi kedua data yang telah dilakukan normalisasi menggunakan *Standard Scaler* menjadi lebih terpusat dengan rata-rata mendekati 0 dan

standar deviasi sekitar 1. Walaupun masih terlihat beberapa nilai ekstrim masih terlihat sebagai outlier, pengaruhnya terhadap skala keseluruhan sudah sangat berkurang secara signifikan.

BAB IV
MODELLING

4.1 K-Means

Sebelum melakukan pemodelan menggunakan algoritma K-Means, jumlah k harus ditentukan terlebih dahulu untuk menentukan jumlah *cluster* optimal. Untuk mencari jumlah k digunakan metode *Elbow Score.* Gambar 4.1 adalah hasil dari distortion score elbow grafik menunjukkan penurunan dari k=2 hingga k=4 sangat signifikan, namun penurunan setelah k=4 menjadi lebih stabil dan grafik membentuk siku (*elbow*) pada k=4 sehingga jumlah *cluster* optimal yang digunakan dalam algoritma K-Means adalah 4 *cluster*.



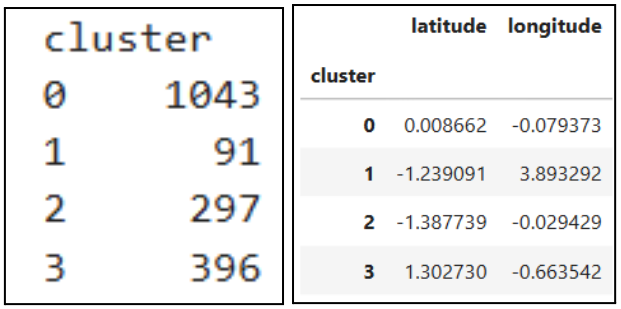
Gambar 4.1 *Distortion Score Elbow*

Setelah jumlah cluster optimal ditentukan dapat dilakukan *clustering* dengan algoritma K-Means untuk melihat data dikelompokkan berdasarkan pola *latitude* dan *longitude*. Gambar 4.3 menunjukkan data terbagi kedalam empat *cluster*, setiap warna merepresentasikan satu *cluster*. Setiap cluster merepresentasikan aktivitas gempa yang terjadi pada *longitude* dan *latitude* tertentu, dalam visualisasi K-Means nilai *longitude* dan *latitude*

telah dilakukan normalisasi dengan *Standard Scaler,* dilakukannya normalisasi karena K-Means sangat sensitif terhadap skala.

Cluster biru muda membentuk kelompok titik yang padat dan memanjang pada bagian atas sebelah kanan grafik, sehingga mencerminkan wilayah gempa di bagian utara-timur. *Cluster* merah memiliki pola yang lebih tersebar dan berada di sisi kiri grafik, sehingga menggambarkan area aktivitas gempa di wilayah barat pada lintang menengah. *Cluster* biru tua menghasilkan pola yang tidak menyebar dan membentuk area yang padat di bagian tengah grafik, menandakan wilayah gempa pada lintang tengah di sisi timur. Sementara itu, cluster pink muncul sebagai kelompok yang terpusat pada bagian kanan bawah grafik, yang menunjukkan persebaran gempa di wilayah timur-selatan dengan penyebaran yang cenderung lebih terbatas.

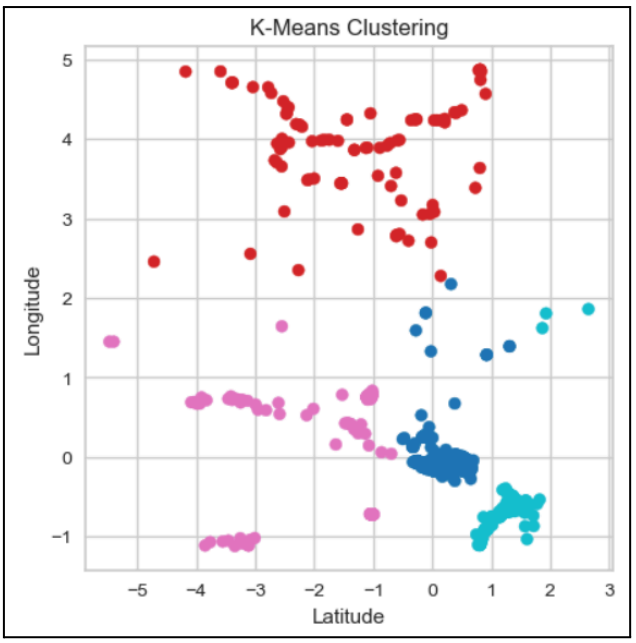
Berdasarkan hasil perhitungan jumlah data setiap cluster, K-Means menghasilkan beberapa cluster dengan jumlah anggota yang bervariasi, berdasarkan hasil dari Elbow Method bahwa cluster sebanyak 4.



cluster	
0	1043
1	91
2	297
3	396

cluster	latitude	longitude
0	0.008662	-0.079373
1	-1.239091	3.893292
2	-1.387739	-0.029429
3	1.302730	-0.663542

Gambar 4.2 Jumlah titik data dalam *K-Means Clustering* dan ciri-ciri berdasarkan average



Gambar 4.3 *Scatter Plot K-Means Clustering*

4.2 DBSCAN

Berdasarkan hasil perhitungan jumlah data setiap *cluster*, DBSCAN menghasilkan beberapa *cluster* dengan jumlah anggota yang bervariasi. *Cluster* terbesar berada pada label 0, 1, 2, dan seterusnya dengan jumlah titik yang jauh dominan dibanding *cluster* lainnya. Sementara itu label cluster -1 menunjukkan *noise*, yaitu data yang tidak dekat dengan *cluster* manapun sehingga titik dianggap tidak masuk dalam *cluster*.

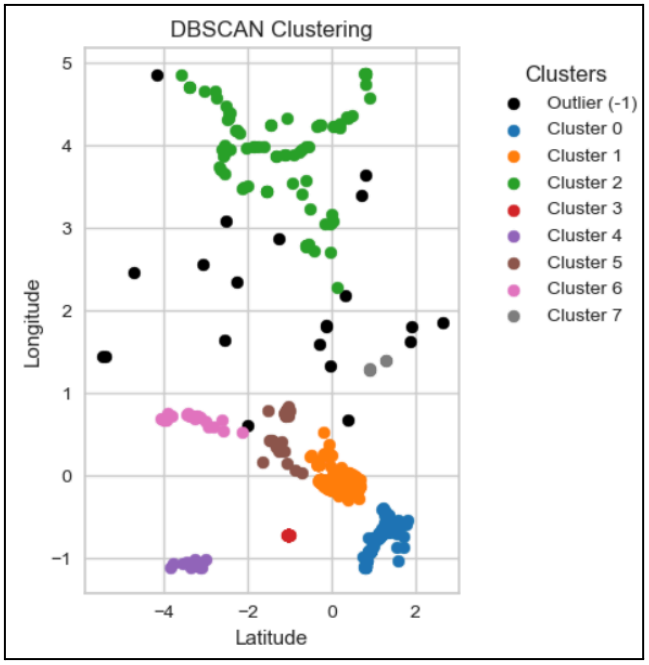
dbscan_cluster	
1	1032
0	393
3	138
5	118
2	83
6	24
-1	21
4	13
7	5

dbscan_cluster	latitude	longitude
-1	-1.204313	2.143661
0	1.296269	-0.682063
1	0.003351	-0.095757
2	-1.159955	3.965106
3	-1.027408	-0.722163
4	-3.318393	-1.078144
5	-1.114537	0.706811
6	-3.345040	0.682511
7	1.078628	1.328250

Gambar 4.4 Jumlah titik data dalam DBSCAN *Clustering* dan ciri-ciri berdasarkan average

Gambar 4.5 menunjukkan hasil *clustering* menggunakan algoritma DBSCAN berdasarkan *latitude* dan *longitude.* Jumlah *cluster* yang dihasilkan oleh DBSCAN adalah

sebanyak 8 *cluster*. Pada visualisasi terlihat bahwa DBSCAN membentuk *cluster* dengan bentuk yang tidak beraturan. *Cluster* besar yaitu *cluster* ungu dan coklat menyebar dan kurang simetris, sedangkan cluster lain membentuk kelompok kecil dengan persebaran yang lebih terbatas. Titik biru tua merupakan *noise*, yang dimana titik tersebut tidak padat.



Gambar 4.5 *Scatter Plot DBSCAN Clustering*

BAB V
EVALUATION

Pada penelitian ini, metrik yang digunakan adalah *Silhouette Score*, sebagai ukuran yang mengevaluasi seberapa baik sebuah data ditempatkan dalam *cluster*-nya. *Silhouette Score* akan menggabungkan 2 komponen utama, yaitu tingkat kedekatan data terhadap anggota *cluster* yang sama (*cohesion*) dan juga tingkat keterpisahan data dari *cluster* lain (*separation*). Nilainya berada pada rentang –1 hingga 1, nilai yang mendekati 1 menandakan bahwa *cluster* yang terbentuk semakin baik, kompak, serta mempunyai batas antar *cluster* yang jelas. Pemilihan metrik ini didasarkan pada kelebihannya yang objektif, fleksibel, dan tidak membutuhkan label data, sehingga sangat sesuai untuk metode *unsupervised* seperti clustering.

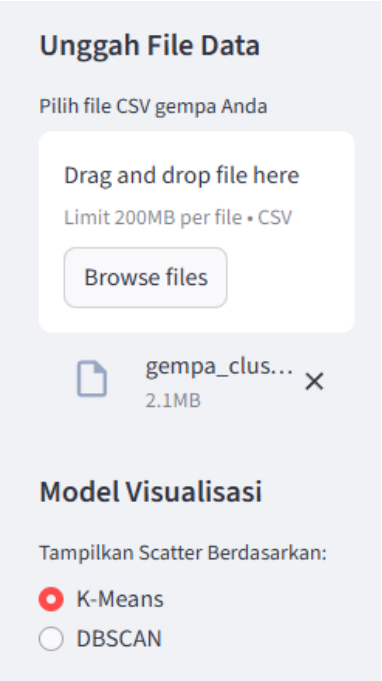
Berikut adalah hasil *Silhouette Score* untuk kedua algoritma *clustering* yang diuji, yaitu K-Means dan DBSCAN

	Algoritma	Silhouette Score
0	K-Means	0.823289
1	DBSCAN	0.899497

Gambar 5.1 *Silhouette Score* algoritma K-Means dan DBSCAN *Clustering*

BAB VI
DEPLOYMENT

Langkah terakhir dalam CRISP-DM dengan implementasi hasil model yang sudah dibuat dapat dipakai di dunia nyata. Hal ini bertujuan untuk membantu pengambilan keputusan, misalnya mengelompokkan wilayah rawan sebagai bentuk pencegahan pembangunan perumahan di wilayah tersebut. Deployment menjelaskan bagaimana model akan dipakai dalam sistem, aplikasi, dashboard, atau laporan.



Gambar 6.1 Sidebar

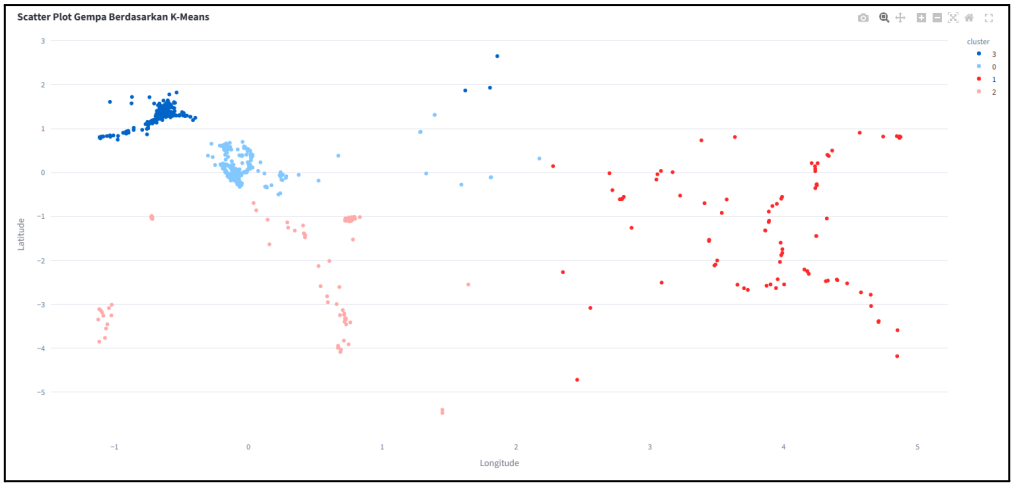
Namun, deployment tidak bisa memberikan model yang statis dikarenakan data akan berubah dari waktu ke waktu [21]. Kasus seperti pola gempa yang selalu berubah, sehingga model harus dipantau, dievaluasi ulang, dan/atau menggunakan model baru yang telah diperbaiki.

Pada tahap awal penggunaan aplikasi dengan menggunakan *tool streamlit* yang digunakan untuk fase *Deployment ini* https://datnal-final-74avpxsqk89s5jq6c7m6dd.streamlit.app/ menyediakan visualisasi melalui opsi *Filter Data* di *sidebar* dengan memilih *cluster* K-Means atau *cluster* DBSCAN, dengan mengunggah *file gempa_clustered_full.csv* yang berada pada bagian *sidebar*. *File* ini berisi dataset gempa bumi yang telah melalui seluruh proses *preprocessing* dan telah memiliki hasil *clustering* dari 2 algoritma, yaitu *K-Means (cluster)* dan *DBSCAN (dbscan_cluster)*.

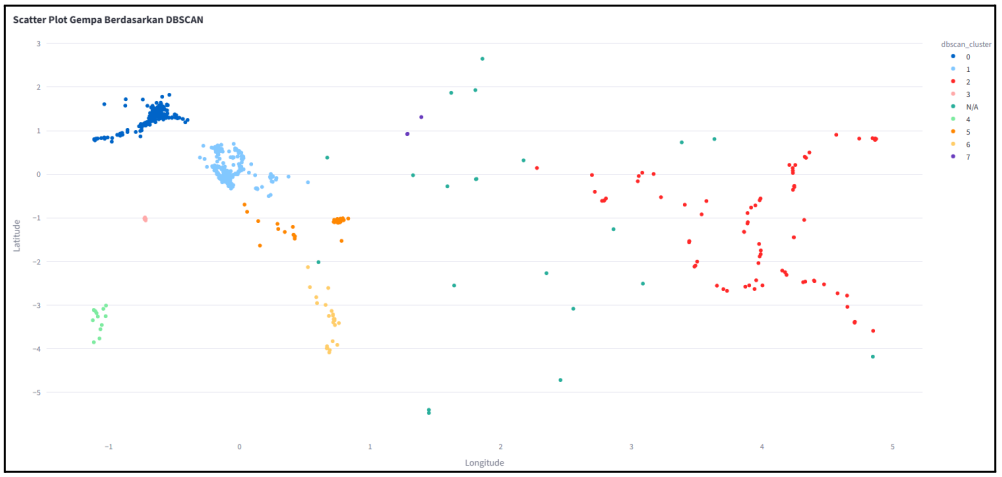
Aplikasi dirancang untuk tidak menampilkan visualisasi apa pun sebelum data berhasil diunggah. Hal ini berfungsi sebagai mekanisme kontrol agar aplikasi tidak melakukan komputasi dengan dataset yang kosong. Dengan demikian, proses alur kerja menjadi lebih aman, jelas, dan terstruktur.

Setelah file berhasil diunggah, aplikasi secara otomatis menghasilkan 3 komponen visual utama, berupa gambaran mengenai karakteristik dan hasil *clustering* pada *dataset* gempa bumi.

a) Scatter plot hubungan cluster:
   - Plot persebaran titik gempa berdasarkan koordinat *longitude* dan *latitude*
   - Setiap cluster dengan warna yang berbeda-beda
   - Melihat wilayah yang memiliki kepadatan gempa tinggi

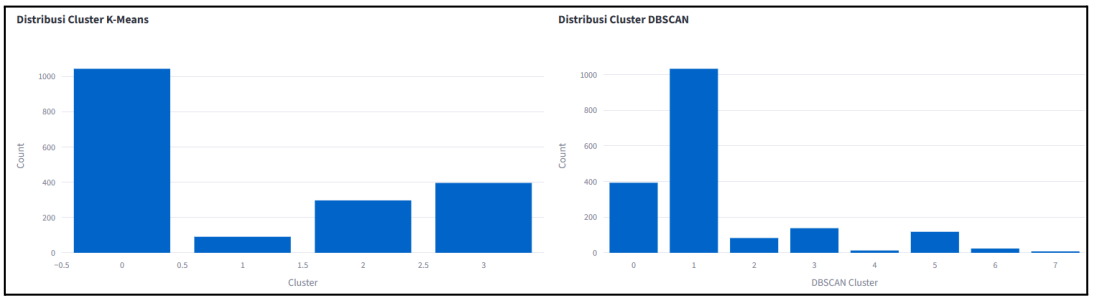


Gambar 6.2 Visualisasi Distribusi Cluster K-Means Berdasarkan Koordinat Lintang dan Bujur



Gambar 6.3 Visualisasi Distribusi Cluster DBSCAN Berdasarkan Koordinat Lintang dan Bujur

b) Bar chart distribusi cluster:
   - Grafik berdasarkan jumlah titik data yang ada di cluster (K-Means) dan dbscan_cluster (DBSCAN)
   - Memberikan gambaran tentang ukuran relatif dari setiap kelompok



Gambar 6.4 Distribusi Frekuensi Cluster K-Means dan DBSCAN

c) Tabel data mentah (*scrollable data table*):
   - Memeriksa data asli per baris
   - Melihat nilai fitur dan cluster secara detail

	latitude	longitude	cluster	dbscan_cluster
0	1.4385	-0.6609	3	0
1	-0.0793	-0.087	0	1
2	-0.0501	-0.1495	0	1
3	1.3351	-0.6706	3	0
4	0.0788	-0.1771	0	1
5	0.0667	-0.0065	0	1
6	-0.0798	-0.1449	0	1
7	-0.33	0.1369	0	1
8	-3.3931	4.7079	1	2
9	-0.1039	-0.0892	0	1

Gambar 6.5 Tabel Data

BAB VII
HASIL DAN PEMBAHASAN

DBSCAN memperoleh nilai *Silhouette Score* tertinggi yaitu 0.899497, dilanjutkan dengan K-Means yang bernilai 0.823289. Kedua nilai yang dihasilkan menunjukkan bahwa DBSCAN menjadi algoritma yang mampu membentuk cluster yang paling kompleks dan memiliki tingkat keterpisahan antar *cluster* paling baik. Sementara K-Means menghasilkan clustering yang cukup baik, namun tetap saja performanya masih berada di bawah DBSCAN karena algoritma ini tidak terlalu optimal untuk pola data yang tidak beraturan.

Dataset gempa bumi memiliki karakteristik pola distribusi yang kompleks dan sering kali tidak berbentuk bulat atau simetris. DBSCAN merupakan algoritma yang paling optimal karena dapat mengenali *cluster* dengan menyesuaikan terhadap variasi kepadatan. Tidak hanya itu, data gempa mengandung sejumlah *noise* yang berupa titik-titik aktivitas yang jarang atau tidak konsisten. DBSCAN memiliki kemampuan alami untuk menandai data seperti ini sebagai *outlier*, sehingga proses *clustering* tidak dipengaruhi oleh titik-titik yang tidak representatif. Maka dari itu, DBSCAN dapat menunjukkan keunggulan signifikan dibandingkan algoritma lainnya dalam konteks data geospasial gempa.

DBSCAN juga tidak mengharuskan pengguna menentukan jumlah *cluster* di awal, berbeda dengan K-Means yang wajib menentukan jumlah *cluster* terlebih dahulu. Hal ini dapat mengakibatkan adanya *bias*. Oleh karena itu, DBSCAN paling optimal dalam pembentukan *cluster* secara alami dengan mengikuti pola distribusi kepadatan data.

BAB VII
KESIMPULAN

K-Means dan DBSCAN diawali dengan *feature selection* dengan hanya menggunakan variabel latitude dan longitude, normalisasi dengan *standar scaler*, kemudian menjalankan masing-masing algoritma sesuai mekanismenya. K-Means membentuk cluster berdasarkan *centroid*, sedangkan DBSCAN berdasarkan kepadatan titik.

Berdasarkan hasil evaluasi performa clustering dengan metrik *Silhouette Score*, nilai yang dihasilkan untuk masing-masing algoritma yaitu K-Means sebesar 0.823289 dan DBSCAN sebesar 0.899497. Kedua nilai tersebut menunjukkan bahwa DBSCAN menjadi algoritma paling optimal karena dapat membentuk *cluster* yang memiliki tingkat *cohesion* dan keterpisahan *separation* yang lebih baik dibandingkan algoritma lainnya.

Penelitian terdahulu menunjukkan ambiguitas oleh Arafat (2023), telah terjawab oleh. penelitian ini yang menunjukkan bahwa DBSCAN unggul dibandingkan K-Means, sehingga secara metrik maupun geologis dalam membentuk cluster kompleks dan menangani noise, dinyatakan sebagai algoritma paling optimal untuk *clustering* data gempabumi.

REFERENSI

[1] A. Rianti, N. W. A. Majid, and A. Fauzi, "CRISP-DM: Metodologi Proyek Data Science," *SENATIB, Universitas Duta Bangsa Surakarta*, Jul. 2023, pp. 107–114.

[2] M. N. Alwi, "CRISP-DM: Tahapan, Studi Kasus, Kelebihan, dan Kekurangan," *Dicoding Blog*. [Online]. Available: https://www.dicoding.com/blog/crisp-dm-tahapan-studi-kasus-kelebihan-dan-kekurangan/. [Accessed: Nov. 16, 2025].

[3] R. Setiawan, "Apa itu Data Mining dan Bagaimana Metodenya," *Dicoding Blog*. [Online]. Available: https://www.dicoding.com/blog/apa-itu-data-mining. [Accessed: Nov. 16, 2025].

[4] United States Geological Survey, "Earthquake Magnitude, Energy Release, and Shaking Intensity," *USGS*. [Online]. Available: https://www.usgs.gov/programs/earthquake-hazards/earthquake-magnitude-energy-release-and-shaking-intensity. [Accessed: Nov 16, 2025]

[5] F. Al-Anshori and D. Apriandanu, "Penerapan Data Mining dalam Analisis Big Data," *Jurnal Teknologi Informasi*, vol. 6, no. 2, 2021.

[6] Coding Studio, "Mengenal Clustering," *Codingstudio.id*. [Online]. Available: https://codingstudio.id/blog/mengenal-clustering/. [Accessed: Nov. 20, 2025].

[7] Dibimbing.id, "Jenis Algoritma Clustering Terbaru yang Jarang Diketahui," *Dibimbing.id*. [Online]. Available: https://dibimbing.id/blog/detail/jenis-algoritma-clustering-terbaru-jarang-diketahui. [Accessed: Nov. 20, 2025].

[8] Telkom University – BDS SBY, "DBSCAN: Mendeteksi Pola dan Outlier di Dunia Data Tak Terstruktur," *telkomuniversity.ac.id*. [Online]. Available: https://bds-sby.telkomuniversity.ac.id/dbscan-mendeteksi-pola-dan-outlier-di-dunia-data-tak-terstruktur/. [Accessed: Nov. 20, 2025].

[9] Informatec Digital, "Algoritma Pengelompokan dan Kategorisasi," *informatecdigital.com*. [Online]. Available:

https://informatecdigital.com/id/algoritma-pengelompokan-dan-pengelompokan/. [Accessed: Nov. 20, 2025].

[10] "Mengenal Feature Selection: Pengertian, Fungsi, dan Contohnya," Course-Net Indonesia, Nov. 5, 2024. [Online]. Available: https://course-net.com/blog/mengenal-feature-selection/

[11] United States Geological Survey (USGS), "What is an earthquake and what causes them to happen?," USGS. [Online]. Available: https://www.usgs.gov/faqs/what-earthquake-and-what-causes-them-happen.
[Accessed: Nov. 29, 2025.]

[12] Badan Meteorologi Klimatologi dan Geofisika (BMKG), "Data Gempabumi," bmkg.go.id. [Online]. Available: https://data.bmkg.go.id/gempabumi/.
[Accessed: Nov. 29, 2025.]

[13] RevoU, "Exploratory Data Analysis (EDA)," revou.co [Online]. Available: https://www.revou.co/kosakata/eda. Accessed: Nov. 29, 2025.

[14] A. Desiani, N. R. Dewi, A. N. Fauza, N. Rachmatullah, M. Arhami, and M. Nawawi, "Handling Missing Data Using Combination of Deletion Technique, Mean, Mode and Artificial Neural Network Imputation for Heart Disease Dataset," *Science and Technology Indonesia*, vol. 6, no. 4, pp. 1–9, Oct. 2021.

[15] A. Perwitasari, R. Septiriana, and Tursina, "Data Preparation Structure untuk Pemodelan Prediktif Jumlah Peserta Ajar Mata Kuliah," *Jurnal Edukasi dan Penelitian Informatika (JEPIN)*, vol. 9, no. 1, pp. 7–15, Apr. 2023.

[16] D. Yusuf and F. Razi, "Analisis Faktor Sosial Ekonomi yang Mempengaruhi Rendahnya Capaian Pendidikan di Indonesia Menggunakan Kombinasi Metode Data Mining," vol. 6, no. 1, pp. 51–62, Jan.–Jun. 2025.

[17] RevoU, "Apa itu Reduksi Data?," revou.co. [Online]. Available: https://www.revou.co/kosakata/reduksi-data. Accessed: Nov. 29 2025.

[18] Course-Net, “Mengenal Feature Selection: Kenapa dan Bagaimana Memilih Fitur yang Tepat dalam Machine Learning,” *Course-Net Blog*, Nov. 2024. [Online]. Available: https://course-net.com/blog/mengenal-feature-selection/

[19] CQF Institute, “What Is Extreme Value Theory?” CQF Institute Blog, 2024. [Online]. Available: https://www.cqf.com/blog/quant-finance-101/what-is-extreme-value-theory

[20] P. Rainer, “Lebih dari 2000 Gempa Terjadi di Indonesia Sepanjang 2023,” GoodStats, 2024. [Online]. Available: https://goodstats.id/article/indonesia-jadi-negara-dengan-gempa-bumi-terbanyak-di-dunia-2023-CfwV7.

[21] R. Maulid, “Teknik Analisis Data CRISP-DM dalam Data Mining,” *DQLab*, Nov. 7, 2022. Accessed: Dec. 3, 2025. [Online]. Available: https://dqlab.id/teknik-analisis-data-crisp-dm-dalam-data-mining

[22] R. R. A. Rahman and A. W. Wijayanto, “Pengelompokan Data Gempa Bumi Menggunakan Algoritma DBSCAN,” Jurnal Meteorologi dan Geofisika, vol. 22, no. 1, pp. 31–38, 2021.

[23] B. Triwijaya, S. Wibowo, and N. L. D. M. Sari, “Performance Comparison of K-Means Algorithm and BIRCH Algorithm in Clustering Earthquake Data in Indonesia with Web-Based Map Visualization,” vol. 8, no. 1, pp. 278–287, 2025.

[24] I. B. F. Arafat, Clustering Gempabumi di Wilayah Regional VII Menggunakan Metode DBSCAN dan K-Means, Tesis. Universitas Islam Negeri Maulana Malik Ibrahim, Malang, 2023.

[25] R. R. A. Rahman and A. W. Wijayanto, "Pengelompokan Data Gempa Bumi Menggunakan Algoritma DBSCAN," Jurnal Meteorologi dan Geofisika, vol. 22(3), pp. 119–128, 2021.

[26] M. Karmenova, A. Tlebaldinova, I. Krak, N. Denissova, G. Popova, and Z. Zhantassova, "An Approach for Clustering of Seismic Events using Unsupervised Machine Learning," Acta Polytechnica Hungarica, vol. 19(5), pp. 7–21, 2022.

[27] H. Hafid, R. Hidayat, and R. H.S, "Implementation of DBSCAN for Earthquake Clustering in Indonesia with Potential Surface Damage," Journal of Mathematics, Computations, and Statistics (JMATHCOS), vol. 8(1), pp. 124–133, 2025.

[28] A. Jain, K. Rathi, Y. Ganguly, A. Kumar, and Y. Bhale, "A Comparative Analysis of DBSCAN, K-Means and Agglomerative Clustering Algorithms for Geospatial Data," Open Access Chapter, (No Volume/Issue Listed), pp. 221-224 (as cited in the document), 2025.