Penerapan Meta-Clustering untuk Menghasilkan Cluster Gempa Bumi yang Lebih Optimal Dibandingkan K-Means dan DBSCAN

Valerie Kurniawan
Department of Information Systems
Faculty of Engineering and Informatics,
Universitas Multimedia Nusantara
Tangerang, Indonesia
valerie.kurniawan@student.umn.ac.id

***Abstract*— Penelitian ini menganalisis pola persebaran spasial data gempa bumi menggunakan teknik klasterisasi untuk mengidentifikasi karakteristik seismik yang dapat mendukung mitigasi bencana. Dengan membandingkan performa algoritma K-Means, DBSCAN, dan Meta-Clustering berdasarkan kemampuannya dalam menangani data geospasial skala besar yang mengandung noise. K-Means dengan pengelompokan yang terstruktur, tapi sensitif terhadap outlier dan cenderung membentuk cluster berbentuk bulat. DBSCAN lebih efektif untuk pola spasial yang tidak beraturan karena mampu mendeteksi area berkepadatan tinggi dan titik noise. Meta-Clustering menggabungkan antara K-Means dan DBSCAN untuk menghasilkan struktur cluster yang lebih stabil dan konsisten. Hasil penelitian menunjukkan bahwa Meta-Clustering mencapai nilai silhouette tertinggi, yang menandakan kualitas pemisahan cluster yang lebih baik dibandingkan algoritma tunggal. Pendekatan ini memberikan representasi pola gempa yang lebih cocok.**

Keywords—cluster, K-Means, DBSCAN, Meta clustering, gempa, Silhoutte Score

I. INTRODUCTION

Gempa bumi merupakan salah satu fenomena alam yang tidak dihindari dan dicegah akibat pergeseran lempeng pada permukaan bumi yang bersifat destruktif [13]. Pemahaman pola kejadian gempa sangat penting untuk mitigasi bencana, terutama dalam mengidentifikasi wilayah rawan berdasarkan lokasi kejadian. Informasi tersebut mendukung pencapaian SDG 11 dan SDG 13 melalui peningkatan ketahanan kota dan penguatan sistem peringatan dini berbasis data, sehingga strategis dalam pengambilan keputusan dalam mengupayakan mitigasi seperti penempatan tata letak perumahan ataupun infrastruktur lainnya

Seiring meningkatnya jumlah data gempa, teknik *data mining* dapat membantu menganalisis data yang berskala besar dan multidimensional. *Clustering* sebagai salah satu teknik *unsupervised learning* untuk mengelompokkan data berdasarkan karakteristik yang sama [12]. Dalam konteks gempa bumi, clustering bermanfaat untuk mengidentifikasi pola sebaran aktivitas seismik sehingga membantu menentukan prioritas mitigasi. Namun, pemilihan algoritma clustering sangat penting karena setiap metode memiliki performa yang berbeda-beda.

Beberapa algoritma yang umum digunakan antara lain K-Means dan DBSCAN. K-Means membentuk cluster berdasarkan centroid, namun sensitif terhadap outlier. Sedangkan, DBSCAN membentuk cluster berdasarkan kepadatan titik menggunakan parameter epsilon dan minPts, yang mampu mendeteksi noise [10]. Penelitian ini membandingkan performa kedua algoritma tersebut dan menerapkan pendekatan *meta-clustering* untuk menghasilkan cluster yang lebih optimal dalam analisis pola gempa bumi di Indonesia.

II. THEORETICAL BASIS

A. CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) terdiri dari 6 tahap, dimulai dari Business Understanding dalam memahami penyebab dan tujuan, dan kebutuhan bisnis [11]. Kedua, Data Understanding untuk mengidentifikasi karakteristik data. Setelah dipahami, dilakukan Data Preparation dengan membersihkan data, menormalisasi, pemilihan fitur agar siap digunakan dalam pemodelan. Lanjut, Modeling dengan membangun dan menguji model menggunakan algoritma clustering. Kemudian, Evaluation dalam menilai hasil dan menentukan algoritma terbaik menggunakan metrik *Silhouette Score*. Terakhir, Deployment yang mengimplementasikan hasil pemodelan, dengan menyajikan peta cluster gempa sebagai bahan analisis dan mitigasi bencana.

B. Machine Learning

Machine learning merupakan algoritma dengan rumus matematis terhadap system dalam mendeteksi pola dari data [11]. Semakin tepat algoritma yang digunakan, semakin baik kualitas keputusan yang dihasilkan. Machine learning bekerja dengan belajar dari data dan pengalaman. Pada umumya, Machine Learning memilih 2 jenis, yaitu Supervised dan Unsupervised.

C. Exploratory Data Analysis

Exploratory Data Analysis (EDA) merupakan proses awal dalam analisis data yang bertujuan memahami struktur, pola, dan kualitas data sebelum masuk ke tahap pemodelan [22]. Melalui EDA, dapat mengetahui tipe data, mendeteksi nilai hilang, anomali, evaluasi distribusi fitur numerik dan kategorikal, serta mengidentifikasi hubungan antar variabel menggunakan visualisasi dan statistik sederhana. Hal ini bertujuan untuk memastikan bahwa data telah bersih, konsisten, dan siap digunakan sehingga model yang dibangun menjadi lebih akurat dan terpercaya [22].

D. Clustering

Clustering merupakan salah satu metode machine learning yang digunakan untuk mengelompokkan data ke dalam beberapa kelompok berdasarkan tingkat kemiripannya. Metode ini digunakan oleh data yang tidak memiliki label atau unsupervised. Setiap objek yang berada dalam satu cluster

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

memiliki kemiripan karakteristik, dibandingkan dengan objek di cluster lainnya [11].

Berbagai algoritma clustering dengan masing-masing mekanisme yang berbeda dalam menentukan cluster, misalnya berdasarkan jarak ataupun kepadatan. Oleh karena itu, pemilihan algoritma perlu disesuaikan dengan karakteristik data dan tujuan analisis agar hasil pengelompokan yang diperoleh lebih optimal.

1) K-Means

K-Means merupakan salah satu algoritma clustering yang bekerja dengan membagi data ke dalam sejumlah cluster K berdasarkan jarak terhadap centroid cluster. Beberapa tahapan cara kerja K-Means, yaitu sebagai berikut.

- Penentuan jumlah cluster dengan menggunakan Elbow Method. Elbow Method berbentuk pola siku untuk mempermudah dalam menentukan nilai k (jumlah cluster) yang optimal. Berdasarkan Within-Cluster Sum of Squares (WCSS) terhadap jumlah klaster (K), yang Dimana nilai WCSS akan menurun seiring bertambahnya nilai K, namun pada titik tertentu penurunannya mulai melambat [14]
- Pemilihan centroid awal secara acak dengan rumus dalam menentukan target awal k-means untuk mendapatkan jarak antar kelompok [12]
- Pengelompokkan objek berdasarkan jarak ke centroid terdekat

2) DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) merupakan algoritma yang membentuk sebuah cluster berdasarkan kepadatan. Cara kerja DBSCAN dengan parameter epsilon dan minPts. Titik-titik dalam suatu area yang memiliki tetangga cukup banyak disebut dengan core point, sebaliknya dengan titik - titik yang tidak memenuhi syarat densitas disebut dengan noise atau outlier. Beberapa tahapan cara kerja DBSCAN, yaitu sebagai berikut.

- Menentukan parameter MinPts sebagai jumlah minimum titik untuk bisa dijadikan sebuah cluster dan Eps sebagai radius pencarian untuk menentukan seberapa jauh dekatnya antar titik [11]
- Memilih titik data (p) yang sedang diproses oleh DBSCAN sebagai acuan awal
- Menghitung nilai Eps untuk semua titik dari titik p
- Jika memenuhi syarat dari parameter eps dan MinPtrs, maka terbentuk sebuah cluster terbentuk dan titik-titik di dalamnya disebut dengan core point. Sedangkan, titik lain akan diberi label sebagai noise point atau border point [9]

3) Meta-Clustering

Meta clustering merupakan pendekatan baru dalam menyelesaikan masalah clustering [1]. Hal ini bertujuan untuk tidak mencari 1 hasil clustering yang paling optimal dan mencegah melakukan evaluasi model yang banyak sekaligus. Konsep dari meta clustering, yaitu clustering dari kumpulan clustering dengan menjalankan beberapa tahap, yaitu sebagai berikut.

- Memiliki banyak clustering dasar (*base-level clustering*)
- Mengukur kemiripan antar clustering dasar yang dihasilkan agar dapat membentuk pengelompokkan clustering yang mirip [1]
- Mengelompokkan kumpulan hasil clustering tersebut pada tingkat yang lebih tinggi (meta level)

E. Stacking

Stacking merupakan machine learning (ML) yang bekerja dengan model-model ML heterogen yang disusun dalam satu atau lebih lapisan[5]. Cara kerja stacking dengan melatih beberapa model clustering dasar, lalu menggunakan sebuah meta-model untuk menggabungkan hasil prediksi dari model-model tersebut [8]. Hal ini bertujuan untuk memanfaatkan beberapa model sekaligus, rendahnya bias dan variance.

F. Silhouette Score

Silhoutte Score merupakan alat ukur metrics untuk mengevaluasi performa keseluruhan dari setiap algoritma. Nilai silhouette menunjukkan seberapa mirip suatu titik data dalam sebuah cluster dibandingkan dengan cluster lainnya. Nilai silhouette berada pada rentang –1 hingga 1, yang dimana semakin mendekati angka 1, semakin bagus algoritma tersebut [10]

- Nilai 1, berarti pengelompokkan cluster sangat baik atau titik data berada sangat dekat dengan cluster-nya sendiri dan jauh dari cluster lain.
- Nilai 0, berarti pengelompokkan cluster kurang baik atau tidak titik data berada di batas antara cluster sehingga tidak jelas titi tersebut lebih cocok masuk cluster yang mana.
- Nilai -1, berarti pengelompokan buruk, atau titik data lebih mirip dengan cluster lain, namun dikelompokkan dengan cluster yang bukan seharusnya

Hal ini sangat penting untuk memahami performa berbagai metode clustering, terutama dalam membedakan cluster yang bermakna dan yang mengandung noise. DBSCAN yang dapat mendeteksi noise atau outlier sangat penting pada data geospasial, karena dapat memengaruhi hasil clustering secara signifikan. Dengan adanya evaluasi matriks ini, dapat menghasilkan perbandingan antar performa K-Means dan DBSCAN yang cocok untuk data gempa bumi yang berskala besar dan komples.

G. Previous Research

Berdasarkan penelitian terdahulu mengenai clustering data gempa bumi, menyatakan bahwa algoritma DBSCAN unggul dalam mengolah data spasial yang tidak terdistribusi secara seragam, seperti data seismik [37], [9], [10]. Berbeda dengan halnya dari penelitian oleh Arafat (2023), yang menggunakan variabel longitude dan latitude pada 1.827 data gempa bumi menemukan bahwa K-Means menghasilkan silhouette score yang lebih tinggi (0,570) dibandingkan DBSCAN (0,486) [36]. Walaupun, penelitian tersebut menyimpulkan bahwa DBSCAN secara kualitatif lebih

optimal karena cluster yang dibentuk lebih akurat dalam merepresentasikan peta sebaran gempa bumi secara geologis.

Ambiguitas ini kontras dengan mayoritas penelitian terdahulu oleh Jain et al (2025), Karmenova et al (2022), dan Rahman & Wijayanto (2021) yang menyatakan DBSCAN lebih optimal dan telah dibuktikan dengan Silhouette Score tinggi hingga 0,8646 [10] dan 0,81091 [35].

Penelitian sebelumnya menunjukkan bahwa metode clustering mampu pengelompokan data geospasial dan lingkungan dengan menemukan pola yang tidak terlihat secara langsung [10]. Hal tersebut relevan dengan penelitian gempa bumi karena data gempa bumi yang terdiri dari koordinat lintang dan bujur yang dimana pola distribusi yang kompleks, sehingga memerlukan metode clustering untuk mengidentifikasi wilayah rawan gempa secara lebih akurat.

Berbagai penelitian terdahulu membuktikan bahwa setiap algoritma clustering memberikan hasil yang berbeda bergantung pada struktur data. K-Means bekerja baik pada data yang cenderung bulat, sedangkan DBSCAN unggul dalam mendeteksi cluster dengan bentuk yang tidak beraturan dan dapat menangani noise [10] [13].

Penelitian sebelumnya juga menegaskan bahwa faktor geografis berperan penting dalam pembentukan cluster. Misalnya, studi pengelompokan gempa di Indonesia menunjukkan bahwa distribusi gempa sangat dipengaruhi oleh kondisi tektonik, zona subduksi, dan interaksi lempeng [12] [9]. Hal ini mendukung penggunaan DBSCAN maupun meta-clustering karena pola gempa tidak mengikuti bentuk cluster bulat seperti K-Means, melainkan mengikuti struktur geologi yang kompleks.

Hasil clustering dalam penelitian terdahulu mendukung pengambilan keputusan dari hasil cluster untuk menentukan wilayah rawan, kebijakan mitigasi bencana, dan meningkatkan kesiapsiagaan daerah [12] [9]. DBSCAN sangat efektif dan lebih unggul dibandingkan metode lain dalam menganalisis fenomena geospasial [9] [13]. Hal ini dikarenakan oleh data gempa bumi banyak memiliki outlier.

Meta-clustering cocok digunakan saat kriteria evaluasi cluster sulit didefinisikan secara tunggal, sebab kualitasnya sangat bergantung pada bagaimana cluster tersebut akan digunakan. Hal ini disebabkan oleh tidak ada klasterisasi tunggal yang dianggap "terbaik", karena tujuan berbeda dapat menuntut struktur pengelompokan yang berbeda juga [1]. Meta-clustering dapat mengatasi hal tersebut dengan mengelompokkan klasterisasi-klasterisasi tersebut di tingkat meta berdasarkan kesamaan (clustering of clusterings), agar mudah dalam mengevaluasi dan menavigasi ruang klasterisasi secara efisien, sehingga dapat memilih hasil yang paling sesuai dengan kebutuhan spesifik,

Metode density-based terbukti lebih efektif untuk pola spasial yang memiliki variasi kepadatan, tidak punya pola teratur dan lebih mirip *cluster-density* daripada cluster berbentuk bulat [4]. Oleh karena itu, meta-clustering berbasis DBSCAN lebih sesuai digunakan dibanding K-Means untuk geospasial gempa, karena mampu mengikuti pola natural dan heterogen dari fenomena alam tersebut.

III. Research Methodology

A. Object of Research

Penelitian ini menggunakan dataset asli yang terdiri dari 75.810 baris dan 22 kolom. Namun, penelitian ini hanya berfokus pada pola persebaran gempa bumi secara geospasial, maka hanya menggunakan 1.827 baris dan 2 kolom meliputi longitude (bujur) dan latitude (lintang).

B. Methods of Collecting data

Dataset gempa bumi yang diperoleh dari platform *Kaggle*, yang berisikan kumpulan data aktivitas seismik yang diperoleh dari United States Geological Survey (USGS) yang memberikan informasi tentang gempa bumi yang terjadi di wilayah Amerika Serikat dan sekitarnya [16].

C. Methods of Research

Penelitian ini dilakukan melalui beberapa tahapan utama CRISP-DM. Tahap Business Understanding diawali dengan identifikasi masalah, kebutuhan, tujuan untuk memahami permasalahan terkait pola persebaran gempa bumi dan menentukan algoritma clustering yang paling optimal untuk mendukung mitigasi bencana. Pemahaman masalah dapat menentukan strategi yang akan di capai pada data mining [24].

Selanjutnya pada tahap Data Understanding yang memahami, identifikasi, dan evaluasi kualitas data untuk siap diproses pada tahap selanjutnya [24], yaitu Data Preparation, yang membangun data mentah menjadi dataset akhir [24]. Proses ini mencakup pengumpulan data, identifikasi variabel, pengecekan duplikasi, outlier, missing value. Selanjutnya, data reduction untuk menurunkan beban komputasi dan normalisasi menggunakan StandardScaler agar variabel latitude dan longitude memiliki skala seragam. Tahapan ini sangat penting untuk memastikan bahwa model clustering dapat bekerja secara optimal dan tidak bias terhadap perbedaan skala fitur.

Pada tahap Modeling, Evaluation, dan Deployment sebagai bagian akhir dari proses analisis. Pemodelan dilakukan menggunakan algoritma clustering K-Means dan DBSCAN, kemudian dievaluasi menggunakan metrik Silhouette Score untuk menilai kualitas pemisahan cluster. DBSCAN dipilih sebagai algoritma paling optimal karena kemampuannya menangani pola data yang kompleks dan mendeteksi noise. Pada tahap deployment, model diterapkan dalam bentuk visualisasi atau aplikasi yang dapat digunakan untuk pengambilan keputusan oleh end user di dunia nyata, seperti pemetaan wilayah rawan gempa guna mendukung upaya mitigasi dan perencanaan pembangunan. Hal tersebut bertujuan sebagai solusi bagi pembuatan laporan yang sederhana dan dapat implementasi proses data mining secara berulang [19].

IV. Result and Discussion

A. Business Understanding

Gempa bumi merupakan fenomena alam yang terjadi akibat pelepasan energi di dalam kerak bumi [15]. Dengan tingginya jumlah kejadian gempa yang dicatat BMKG setiap tahun, pemahaman pola sebaran gempa menjadi penting untuk mitigasi bencana [27]. Analisis geospasial ini juga mendukung pencapaian SDG 11 dan SDG 13 karena membantu pemerintah mengidentifikasi wilayah rawan gempa dan merencanakan pembangunan yang lebih aman [28].

Perbandingan antara algoritma K-Means dan DBSCAN dalam mengelompokkan pola geospasial gempa bumi berdasarkan koordinat, dengan melakukan penilaian dalam menangani data besar, mengenali pola wilayah, dan menghadapi outlier. Diharapkan dapat menghasilkan kontribusi bagi pengembangan metode clustering untuk data seismic.

B. Data Understanding

Dataset yang digunakan adalah usgs.csv, yang berisikan kumpulan data aktivitas seismik yang diperoleh dari United States Geological Survey (USGS) yang memberikan informasi tentang gempa bumi yang terjadi di wilayah Amerika Serikat dan sekitarnya.

TABLE I. Column Details

Nama Kolom	Tipe Data	Deskripsi
time	*datetime*	Waktu terjadinya gempa bumi
latitude	*float*	Garis lintang lokasi gempa
longitude	*float*	Garis bujur lokasi gempa
depth	*float*	Kedalaman pusat gempa (km)
mag	*float*	Magnitudo gempa
magType	*string*	Jenis metode pengukuran magnitudo
nst	*integer*	Jumlah stasiun seismik untuk perhitungan magnitudo
gap	*float*	Jarak sudut maksimum antara stasiun seismik
dmin	*float*	Jarak ke stasiun terdekat
rms	*string*	Root-mean-square residu waktu gelombang seismik
net	*string*	Jaringan seismik deteksi gempa
updated	*datetime*	Waktu berakhir data diperbaharui
place	*string*	Deskripsi lokasi kejadian
horizontalError	*float*	Perkiraan kesalahan posisi horizontal
depthError	*float*	Perkiraan kesalahan pengukuran kedalaman
magError	*float*	Perkiraan kesalahan nilai magnitudo
magnst	*integer*	Jumlah stasiun yang dipakai untuk menghitung magError
Status	*string*	Status peninjauan kejadian gempa
locationSource	*string*	Sumber penentuan lokasi gempa

Dataset dengan 75.810 baris dan 22 kolom ini diubah ke dalam DataFrame untuk memudahkan eksplorasi. Akibat fokus utama adalah pola persebaran gempa secara geospasial, maka dilakukan *feature selection* untuk memilih fitur yang paling relevan, yaitu lintang dan bujur untuk meningkatkan efisiensi komputasi dan memastikan hasil clustering lebih akurat. Kedua variable tersebut telah bertipe *float*, tidak memiliki missing value sehingga siap digunakan dalam perhitungan.

```
latitude     0
longitude    0
```

Fig. 1. Hasil Pengecekan Missing Value

Pada pengecekan duplikasi data terdapat 734 berarti jumlah lokasi gempa yang muncul ulang di tempat yang sama persis. Pada umumnya, jika ada nilai duplikasi maka perlu melakukan penghapusan. Namun, berbeda hal dengan konteks gempa bumi yang dimana sangat wajar bahwa adanya duplikasi karena gempa bisa terjadi berulang kali di lokasi yang sama. Oleh sebab itu, tidak perlu penghapusan duplikasi data pada fitur utama.

```
np.int64(734)
```

Fig. 2. Jumlah Duplikasi

Pada pengecekan outlier terdeteksi ribuan outlier pada setiap fitur. Namun, dalam konteks geospasial gempa, bahwa outlier justru merupakan informasi penting untuk mengetahui pola aktivitas seismik yang relevan dengan dunia nyata. Jika dihapuskan akan menghilangkan realitas alam.

```
latitude: 3821 outlier
longitude: 4687 outlier
```

Fig. 3. Jumlah Outlier

Visualisasi distribusi lokasi gempa dilakukan untuk melihat pola distribusi lokasi gempa berdasarkan latitude dan longitude. Hasil visualisasi menunjukkan persebaran lokasi gempa berada pada latitude -60 hingga 80, dan longitude -150 hingga 150. Persebaran titik gempa tidak merata, titik paling banyak terjadinya gempa berada pada longitude -150 hingga -100 dan longitude 100 hingga 150 di wilayah Pesisir Barat Benua Amerika [29].

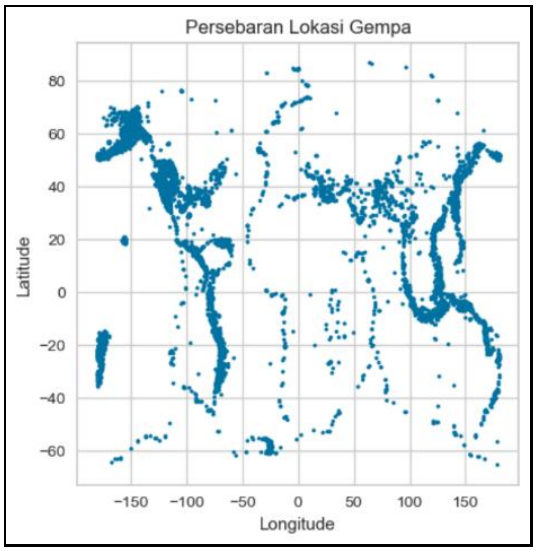


Fig. 4. Scatter Plot Persebaran Lokasi Gempa

Latitude atau lintang merupakan garis horizontal yang mengukur jarak suatu titik ke utara atau selatan dari Garis Khatulistiwa (0°) [30]. Pada Fig 5 menunjukkan bahwa sebagian besar kejadian gempa bumi berada pada rentang sekitar 20° hingga 60° lintang di wilayah lintang menengah. Sementara, frekuensi rendah di bawah −40° atau di atas 80°, yang jarang terjadi gempa

Longitude atau bujur merupakan garis vertikal yang mengukur jarak suatu titik ke timur atau barat dari Meridian Utama [30]. Pada Fig 5 menunjukkan bahwa gempa bumi paling banyak terjadi di sekitar −170° hingga −100° bujur. Sementara frekuensi rendah dari 0° hingga 150° jarang terjadi gempa.

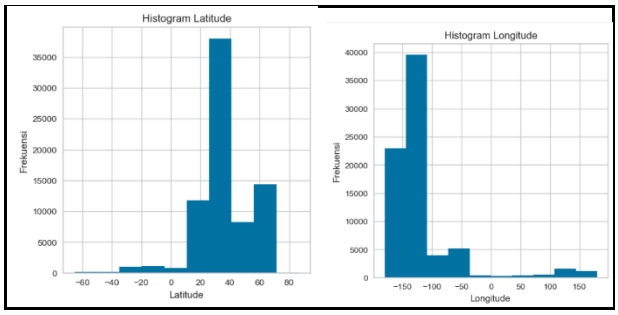


Fig. 5. Histogram Latitude dan Longitude

C. *Data Preparation*

Dataset yang berjumlah sangat besar, maka diperlukan reduksi data dengan mengambil sampel sebanyak 1.827 data dari 75.810 dan dipilih secara acak. Hal ini bertujuan untuk menghindari beban komputasi berlebih.

Normalisasi menggunakan Standard Scaler untuk menyamakan skala variabel numerik dan penting bagi K-Means karena algoritma sensitif terhadap skala fitur [33]. Standard Scaler dengan perhitungan rata-rata 0 dan simpangan baku 1, ideal untuk data gempa dengan nilai ekstrim [34].

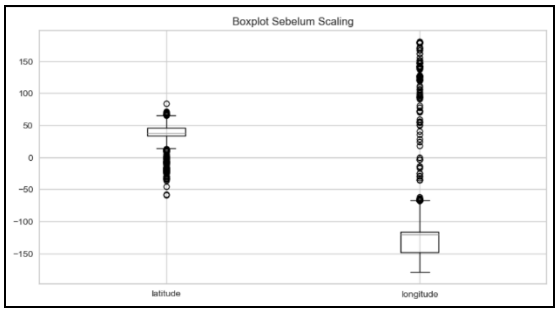


Fig. 6. Boxplot sebelum Normalisasi

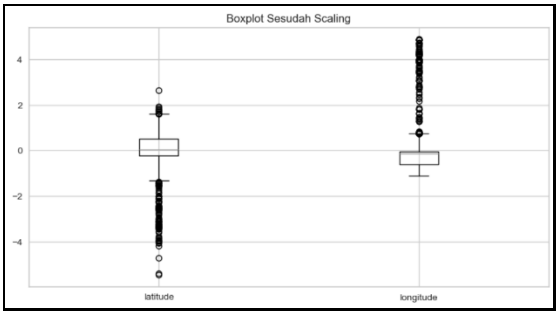


Fig. 7. Boxplot setelah normalisasi

D. *Modelling*

1) *K-Means*

Pemodelan K-Means diawali dengan menentukan jumlah k sebagai jumlah cluster. Metode untuk mendapatkan nilai k secara optimal adalah Elbow Method. Berdasarkan Fig 8 menunjukkan bahwa terjadi penurunan drastis dari k=2 hingga k=4. Penurunan setelah k=4 menjadi lebih stabil dan grafik membentuk siku (elbow), sehingga jumlah cluster optimal adalah 4 cluster.

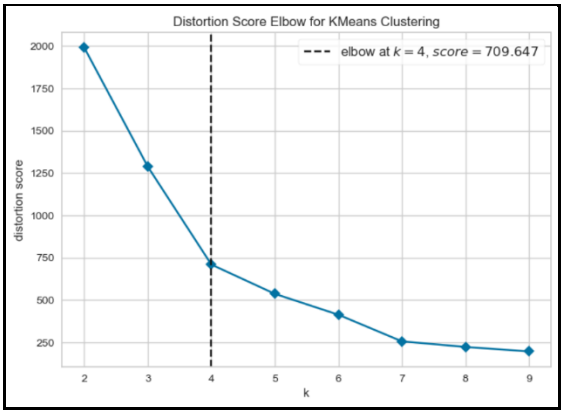


Fig. 8. Elbow Method Menentukan nilai K yang optimal

Selanjutnya, pemilihan centroid dengan asumsi pengambilan langsung dari data sebagai representasi 1 data unik dengan karakteristik berbeda berdasarkan latitude dan longitude [33]. Setelah penentuan letak centroid, dilanjutkan dengan perhitungan jarak

seluruh data ke setiap centroid menggunakan rumus Euclidean Distance.



Fig. 9. Penentuan Letak Centroid

Hasil akhirnya disimpan dalam label sebanyak 4 cluster dengan jumlah data pada pengelompokkan setiap clusternya.

cluster	
0	1043
1	91
2	297
3	396

Fig. 10. Pembagian 4 Cluster K-Means

Pada akhirnya mendapatkan jumlah data setiap clusternya dengan ciri-ciri dengan nilai rata-rata dari latitude dan longitudenya.

cluster	latitude	longitude
0	0.008662	-0.079373
1	-1.239091	3.893292
2	-1.387739	-0.029429
3	1.302730	-0.663542

Fig. 11. Ciri-Ciri Setiap Cluster K-Means

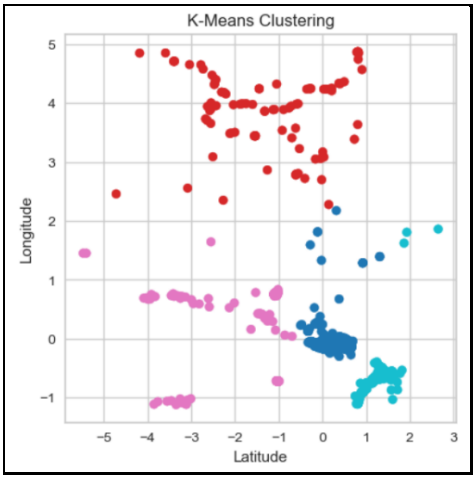


Fig. 12. Scatter Plot K-Means Clustering

2) DBSCAN

Dalam DBSCAN, terdapat 3 komponen utama, yaitu ε (eps), min_samples, dan label dalam pembentukan cluster berdasarkan kepadatan titik. Nilai eps dengan sejauh 0.5 dan min_samples berjumlah minimal terdapat 5 titik dalam radius eps tersebut agar sebuah area dianggap cukup padat untuk membentuk cluster.

Hasil akhirnya disimpan dalam label, yaitu nomor cluster untuk setiap titik (misalnya 0, 1, 2, dan seterusnya). Titik yang tidak memenuhi kepadatan yang cukup diberi label –1 yang berarti noise atau tidak masuk cluster mana pun. Dengan kombinasi parameter ini, DBSCAN mampu menemukan pola kepadatan alami dalam data gempa tanpa harus menentukan jumlah cluster di awal [10].

dbscan_cluster	
1	1032
0	393
3	138
5	118
2	83
6	24
-1	21
4	13
7	5

Fig. 13. Pembagian Cluster DBSCAN

Pada akhirnya mendapatkan jumlah data setiap clusternya dengan ciri-ciri dengan nilai rata-rata dari latitude dan longitudenya.

dbscan_cluster	latitude	longitude
-1	-1.204313	2.143661
0	1.296269	-0.682063
1	0.003351	-0.095757
2	-1.159955	3.965106
3	-1.027408	-0.722163
4	-3.318393	-1.078144
5	-1.114537	0.706811
6	-3.345040	0.682511
7	1.078628	1.328250

Fig. 14. Ciri-Ciri Setiap Cluster DBSCAN

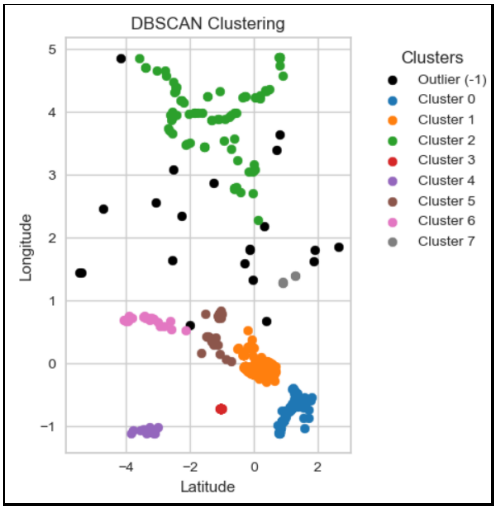


Fig. 15. Scatter Plot DBSCAN Clustering

3) Optimalization DBSCAN

Pada proses optimasi DBSCAN, parameter eps dan min_samples dengan menggunakan pendekatan Grid Search. Grid Search bekerja dengan metode sistematis untuk mencari kombinasi optimal dari hyperparameter [34]. Diawali dengan menentukan parameter eps_list (0.5, 0.7, 0.9) dan min_samples_list (3, 5) guna uji seluruh kombinasi parameter, seperti (0.5, 3), (0.5, 5), (0.7, 3), (0.7, 5), (0.9, 3), (0.9, 5). Setiap kombinasi dihitung nilai silhouette score-nya dan memilih nilai paling tinggi, itulah parameter yang terbaik DBSCAN adalah eps = 0.5 dan min_samples = 3 dengan silhouette score sebesar 0.823.

```
eps=0.5, min_samples=3, silhouette=0.899
eps=0.5, min_samples=5, silhouette=0.899
eps=0.7, min_samples=3, silhouette=0.899
eps=0.7, min_samples=5, silhouette=0.899
eps=0.9, min_samples=3, silhouette=0.899
eps=0.9, min_samples=5, silhouette=0.899

PARAMETER TERBAIK: (0.5, 3)
Silhouette terbaik : 0.899
```

Fig. 16. Pembagian Cluster DBSCAN

Setelah mendapatkan parameter yang optimal, DBSCAN dapat dijalankan untuk membentuk model final dengan menghasilkan label cluster. Nilai cluster hasil DBSCAN tersebut disimpan ke dalam kolom *dbscan_cluster* sehingga dataset memiliki penanda kelompok yang terbentuk secara optimal berdasarkan kedekatan spasial (*latitude* dan *longitude*) dan karakteristik gempa lainnya.

```
eps_best, min_best = best_params
db_best = DBSCAN(eps=eps_best, min_samples=min_best).fit(gempa_sample)
labels_best = db_best.labels_

gempa_sample['dbscan_cluster'] = labels_best
```

Fig. 17. Pembagian Cluster DBSCAN

Untuk mengevaluasi kualitas cluster tanpa data *noise*, dilakukan perhitungan *Silhouette Score* tanpa *label* −1. Dengan membuat *mask* untuk menyaring data valid dan menghitung skor pada subset tersebut, diperoleh nilai Silhouette sebesar 0.824. Hasil ini menunjukkan bahwa cluster DBSCAN semakin jelas ketika tidak melibatkan titik-titik noise.

```
mask = labels_best != -1

sil_no_noise = silhouette_score(
    gempa_sample[mask],
    labels_best[mask]
)

print("\nSilhouette tanpa noise:", round(sil_no_noise, 3))
print("Jumlah noise (-1):", sum(labels_best == -1))
print("Jumlah cluster:", len(set(labels_best)) - (1 if -1 in labels_best else 0))

Silhouette tanpa noise: 0.91
Jumlah noise (-1): 17
Jumlah cluster: 9
```

Fig. 18. Pembagian Cluster DBSCAN

4) Meta Clustering

Kedua hasil label dari algoritma K-Means dan DBSCAN digabungkan ke dalam satu matriks menggunakan np.column_stack(). Proses ini menghasilkan fitur baru bernama stacked features, yaitu 2 kolom yang masing-masing berisi label cluster dari K-Means dan DBSCAN. Gabungan ini sebagai model meta-clustering berikutnya untuk mempelajari pola konsensus dari 2 algoritma dasar dan menghasilkan pengelompokan yang lebih stabil [2].

```
X_stack = np.column_stack([
    kmeans_labels,
    dbscan_labels])
```

Fig. 19. Stacking Label K-Means dan DBSCAN

Setelah itu, meta-clustering menggunakan DBSCAN dengan parameter terbaik yang diperoleh sebelumnya. Hasil label final mendapatkan pola dari kedua algoritma dasar, yang dimana setiap titik data diberi 3 jenis label sekaligus, yaitu kmeans_cluster, dbscan_cluster, dan final_cluster. Dengan bgeitu, dapat dibandingkan bagaimana meta-clustering menggabungkan informasi dari kedua metode untuk menghasilkan struktur cluster akhir yang lebih adaptif terhadap karakteristik geospasial gempa.

```
meta = DBSCAN(eps=eps_best, min_samples=min_best)
final_labels = meta.fit_predict(X_stack)

gempa_sample['kmeans_cluster'] = kmeans_labels
gempa_sample['dbscan_cluster'] = dbscan_labels
gempa_sample['final_cluster'] = final_labels
```

Fig. 20. Proses Meta-Clustering Menggunakan DBSCAN pada Label Gabungan

Hasil akhirnya disimpan dalam label, yaitu nomor cluster untuk setiap titik (misalnya 0, 1, 2, dan seterusnya). Pada Fig 21 menunjukkan jumlah data setiap clusternya dengan ciri-ciri dengan nilai rata-rata dari latitude dan longitudenya.

```
final_cluster
1     1032
0      393
3      138
6      118
2       83
7       24
5       13
4        8
11       6
10       5
8        4
9        3
```

final_cluster	latitude	longitude
0	1.296269	-0.682063
1	0.003351	-0.095757
2	-1.159955	3.965106
3	-1.027408	-0.722163
4	-2.060129	3.148231

Fig. 21. Pembagian Cluster Meta-Clustering beserta Ciri-Ciri

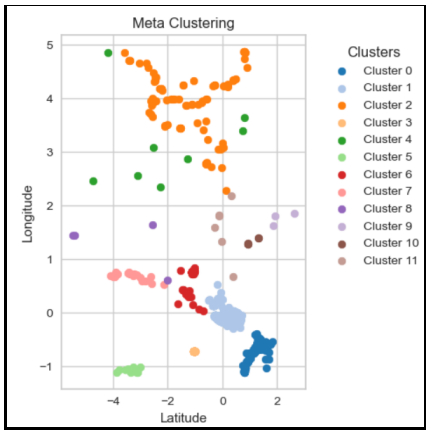


Fig. 22. Scatter Plot Meta Clustering

E. Evaluation

Pada tahap awal analisis, 2 algoritma dasar yaitu K-Means dan DBSCAN dalam mengidentifikasi pola sebaran gempa berdasarkan latitude dan longitude. K-Means menghasilkan Silhouette Score sebesar 0.823289, menunjukkan bahwa pemisahan cluster yang cukup baik namun masih dipengaruhi oleh bentuk cluster yang cenderung bulat. DBSCAN menghasilkan Silhouette Score sebesar 0.899497, menunjukkan bahwa mampu mendeteksi kepadatan titik gempa yang tidak beraturan dan mengenali titik-titik anomali sebagai outlier.

Untuk meningkatkan kualitas evaluasi, titik-titik yang diklasifikasikan sebagai noise oleh DBSCAN (label -1) dihilangkan dari perhitungan sehingga menghasilkan konfigurasi DBSCAN tanpa outlier. Pendekatan ini sedikit meningkatkan Silhouette Score menjadi 0.909743. Hal ini menunjukkan bahwa outlier tidak berpengaruh besar terhadap kualitas pemisahan cluster pada dataset gempa.

Penerapan Meta Clustering dengan menggabungkan label K-Means dan DBSCAN dengan diklasterisasi ulang menggunakan model DBSCAN optimal. Pendekatan ini menghasilkan Silhouette Score lebih tinggi yang mencapai 0.917243. Maka dari itu, Meta-Clustering merupakan metode terbaik dibandingkan K-Means, DBSCAN standar, maupun DBSCAN tanpa outlier.

	Algoritma	Silhouette Score
0	K-Means	0.823289
1	DBSCAN	0.899497
2	DBSCAN w/o outlier	0.909743
3	Meta-Clustering	0.917243

Fig. 23. Perbandingan Silhouette Score Setiap Model

ACKNOWLEDGMENT

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Ibu Irmawati, selaku dosen pengampu mata kuliah Data Analyst, atas bimbingan, arahan, dan dukungan selama proses penyusunan paper ini. Penulis juga menyampaikan terima kasih kepada para teman anggota bernama Evelyn Gracia dan Kelvinia yang telah membantu dalam berdiskusi, kolaborasi, dan semangat belajar bersama. Hal tersebut menciptakan lingkungan pembelajaran yang positif dan membantu memperluas sudut pandang. Penelitian ini diharapkan dapat menjadi landasan bagi studi lanjutan dalam analisis pola seismik dan mendukung dalam pengambilan keputusan yang tepat dan strategis.

REFERENCES

[1] Caruana, R., Elhawary, M., Nguyen, N., & Smith, C. (n.d.). *Meta Clustering*.

[2] Cesario, E., Lindia, P., & Vinci, A. (2024). A scalable multi-density clustering approach to detect city hotspots in a smart city. *Future Generation Computer Systems*, *157*, 226–236. https://doi.org/10.1016/j.future.2024.03.042

[3] Januzaj, Y., Beqiri, E., & Luma, A. (2023). Determining the Optimal Number of Clusters using Silhouette Score as a Data Mining Technique. *International Journal of Online and Biomedical Engineering*, *19*(4), 174–182. https://doi.org/10.3991/ijoe.v19i04.37059

[4] Mahmudur Rahman Khan, M., Abu Bakr Siddique, M., Bente Arif, R., & Rahman Oishe, M. (n.d.). ADBSCAN: Adaptive Density-Based Spatial Clustering of Applications with Noise for Identifying Clusters with Varying Densities.

[5] Ploshchik, I., Chatzimparmpas, A., & Kerren, A. (2023). MetaStackVis: Visually-Assisted Performance Evaluation of Metamodels. *IEEE Pacific Visualization Symposium*, *2023-April*, 207–211. https://doi.org/10.1109/PacificVis56936.2023.00030

[6] Sutramiani, N. P., Arthana, I. M. T., Lampung, P. F., Aurelia, S., Fauzi, M., & Darma, I. W. A. S. (2024). The Performance Comparison of DBSCAN and K-Means Clustering for MSMEs Grouping based on Asset Value and Turnover. *Journal of Information Systems Engineering and Business Intelligence*, *10*(1), 13–24. https://doi.org/10.20473/jisebi.10.1.13-24

[7] Tao, R., & Thill, J.-C. (2016). A Density-Based Spatial Flow Cluster Detection Method. *International Conference on GIScience Short Paper Proceedings*, *1*. https://doi.org/10.21433/b3118mf4r9rw

[8] Yadav, S., & Sharma, S. (2024). Research Analysis on Clustering Ensemble Methods. In *Journal of Computational Analysis and Applications* (Vol. 33, Issue 4).

[9] Hardianti Hafid, Rahmat Hidayat, & Rahmat H. S. (2025). Implementation of DBSCAN for Earthquake Clustering in Indonesia with Potential Surface Damage. Journal of Mathematics, Computations and Statistics, 8(1), 124–133. https://doi.org/10.35580/jmathcos.v8i1.7318

[10] Jain, A., Rathi, K., Ganguly, Y., Kumar, A., & Bhale, Y. (2025). A Comparative Analysis of DBSCAN, K-Means and Agglomerative Clustering Algorithms for Geospatial Data (pp. 212–221). https://doi.org/10.2991/978-94-6463-716-8_18

[11] Medikawati Taufiq, R., Firdaus, R., Handayani, F., Fadhilla Muarif, P., & Rindriani Rizqy, R. (n.d.). Density-Based Clustering untuk Pemetaan Daerah Rawan Gempa Bumi di Wilayah Sumatera Barat Menggunakan Metode DBSCAN. https://www.usgs.gov/

[12] Prasetio, A., Makmun, M., & Dwi, M. N. (2023). Analisis Gempa Bumi Di Indonesia Dengan Metode Clustering. Bulletin of Information Technology (BIT), 4(2), 338–343. https://doi.org/10.47065/bit.v3i1

[13] Rizky, R., Rahman, A., & Wijayanto, A. W. (n.d.). PENGELOMPOKAN DATA GEMPA BUMI MENGGUNAKAN ALGORITMA DBSCAN GROUPING EARTHQUAKES DATA USING DBSCAN ALGORITHM.

[14] Baromim Triwijaya, Setyoningsih Wibowo, & Nur Latifah Dwi Mutiara Sari. (2025). Performance Comparison of K-Means Algorithm and BIRCH Algorithm in Clustering Earthquake Data in Indonesia with Web-Based Map Visualization. *JURNAL TEKNOLOGI DAN OPEN SOURCE*, *8*(1), 278–287. https://doi.org/10.36378/jtos.v8i1.4400

[15] Dwitiyanti, N., Ayu Kumala, S., & Dwi Handayani, S. (n.d.). PENERAPAN METODE K-MEANS PADA KLASTERISASI WILAYAH RAWAN GEMPA DI INDONESIA Implementation of K-Means Method in Classterization of Earthquake Prone Areas in Indonesia.

[16] The Devastator, "Earthquakes (USGS: Magnitude, Location, and Freq)," Kaggle, 2022. [Online]. Available: https://www.kaggle.com/datasets/thedevastator/uncovering-geophysical-insights-analyzing-usgs-e. [Accessed: 08-Dec-2025].

[17] Ardan, T. S., Anggara Mujiatno, S., & Akbar, B. A. (2025). IMPLEMENTASI DATA ANALYTICS MENGGUNAKAN METODOLOGI CRISP-DM (STUDI KASUS DATA BIKE SALES IN EUROPE PADA PLATFORM KAGGLE). JSiI | Jurnal Sistem Informasi, 12(2), 10–15.

[18] Mahmudur Rahman Khan, M., Abu Bakr Siddique, M., Bente Arif, R., & Rahman Oishe, M. (n.d.). ADBSCAN: Adaptive Density-Based Spatial Clustering of Applications with Noise for Identifying Clusters with Varying Densities.

[19] Shimaoka, A. M., Ferreira, R. C., & Goldman, A. (2024). The evolution of CRISP-DM for Data Science: Methods, Processes and Frameworks. SBC Reviews on Computer Science, 4(1), 28–43. https://doi.org/10.5753/reviews.2024.3757

[20] Tao, R., & Thill, J.-C. (2016). A Density-Based Spatial Flow Cluster Detection Method. International Conference on GIScience Short Paper Proceedings, 1. https://doi.org/10.21433/b3118mf4r9rw

[21] Uc Castillo, J. L., Marín Celestino, A. E., Martínez Cruz, D. A., Tuxpan Vargas, J., Ramos Leal, J. A., & Morán Ramírez, J. (2024). A systematic review of Machine Learning and Deep Learning approaches in Mexico: challenges and opportunities. In Frontiers in Artificial Intelligence (Vol. 7). Frontiers Media SA. https://doi.org/10.3389/frai.2024.1479855

[22] J. Johnkutty, S. Haque, and J. Davis T, "Exploratory Data Analysis using Machine learning – Behaviour Based Safety," J. Electrical Syst., vol. 20, no. 7s, pp. 744–754, 2024.

[23] T. Doleck, P. Agand, and D. Pirrotta, "Design, Development, and Use of an Exploratory Data Analysis Tool," Int. J. Educ. Media Technol., vol. 18, no. 2, pp. 61–75, 2024.

[24] Yudiana, Y., Yulia Agustina, A., & Nur Khofifah, dan. (2023). Prediksi Customer Churn Menggunakan Metode CRISP-DM Pada Industri Telekomunikasi Sebagai Implementasi Mempertahankan Pelanggan (Vol. 8, Issue 1). http://e-journal.lp2m.uinjambi.ac.id/ojp/index.php/ijoieb

[25] Scitovski, Sanja. (2017). A density-based clustering algorithm for earthquake zoning. Computers & Geosciences. 110. 10.1016/j.cageo.2017.08.014.

[26] B. A. Pimentel and A. C.P.L.F. de Carvalho, "A meta-learning approach for recommending the number of clusters for clustering algorithms," Knowledge-Based Systems, vol. 195, p. 105682, 2020, doi: 10.1016/j.knosys.2020.105682.

[27] Lingkungan, P., Pendidikan, D., Pelatihan Badan, M., Klimatologi, D., Geofisika, M., Pendidikan, P., Pelatihan, D., Badan, /, Klimatologi, M., Geofisika, D., & Madya, W. (2021). KESIAPSIAGAAN INDIVIDU TERHADAP BENCANA GEMPA BUMI DI. In Jurnal Widya Climago (Vol. 3, Issue 2). http://media.bmkg.go.id

[28] Swanda Narastu, R. (2025). Analisis Data Eksplorasi Dataset Gempa Bumi Indonesia. Jurnal Sains Student Research, 3(1), 136–142. https://doi.org/10.61722/jssr.v3i1.3266

[29] GPS-Coordinates.net, "Map of USA - GPS coordinates," GPS-Coordinates.net, [Online]. Available: https://www.gps-coordinates.net/map/country/US. [Accessed: 08-Dec-2025].

[30] Dinargeo, "Longitude & Latitude, apa perbedaan keduanya dan bagaimana cara menentukannya?," Dinargeo, [Online]. Available: https://dinargeo.co.id/blog/longitude-latitude/. [Accessed: 08-Dec-2025].

[31] RevoU, "Apa itu Reduksi Data?," revou.co. [Online]. Available: https://www.revou.co/kosakata/reduksi-data. Accessed: Nov. 29 2025.

[32] D. Yusuf and F. Razi, "Analisis Faktor Sosial Ekonomi yang Mempengaruhi Rendahnya Capaian Pendidikan di Indonesia Menggunakan Kombinasi Metode Data Mining," vol. 6, no. 1, pp. 51–62, Jan.–Jun. 2025.

[33] B. Triwijaya, S. Wibowo, and N. L. D. M. Sari, "Performance Comparison of K-Means Algorithm and BIRCH Algorithm in Clustering Earthquake Data in Indonesia with Web-Based Map Visualization," vol. 8, no. 1, pp. 278–287, 2025.

[34] DQLab. "Grid Search vs Random Search Algoritma Data Science," DQLab, [Online]. Available: https://dqlab.id/grid-search-vs-random-search-algoritma-data-science. [Accessed: 9 Dec. 2025].

[35] R. R. A. Rahman and A. W. Wijayanto, "Pengelompokan Data Gempa Bumi Menggunakan Algoritma DBSCAN," Jurnal Meteorologi dan Geofisika, vol. 22, no. 1, pp. 31–38, 2021.

[36] I. B. F. Arafat, Clustering Gempabumi di Wilayah Regional VII Menggunakan Metode DBSCAN dan K-Means, Tesis. Universitas Islam Negeri Maulana Malik Ibrahim, Malang, 2023.

[37] M. Karmenova, A. Tlebaldinova, I. Krak, N. Denissova, G. Popova, and Z. Zhantassova, "An Approach for Clustering of Seismic Events using Unsupervised Machine Learning," Acta Polytechnica Hungarica, vol. 19(5), pp. 7–21, 2022.