Perbandingan Kinerja Linear Regression dan Boosted Tree Regression dalam Prediksi Harga Properti

Valerie Kurniawan
Information Systems
Multimedia Nusantara University
Banten, Indonesia
valerie.kurniawan@student.umn.ac.id

***Abstract*— Prediksi harga properti yang akurat sangat krusial bagi pembeli, penjual, dan investor di tengah dinamika pasar perumahan yang heterogen. Penelitian ini bertujuan untuk membandingkan performa algoritma Linear Regression dan Boosted Tree Regressor (XGBoost) dalam memprediksi harga properti berdasarkan karakteristik fisik dan lokasi. Implementasi model menggunakan Google Big Query ML dan hasil evaluasi menunjukkan bahwa model Linear Regression hanya mampu menghasilkan nilai R^2 sebesar 59% dengan RMSE 0.13, sedangkan Boosted Tree Regressor (XGBoost) menunjukkan performa yang jauh lebih unggul dengan nilai R^2 mencapai 79% dengan RMSE 0.04. Ketidakteraturan pola (non-linear) pada variabel menjadi faktor utama rendahnya akurasi model linear. Penelitian ini membuktikan bahwa pendekatan ensemble learning melalui XGBoost lebih efektif.**

Keywords: google big query machine learning, prediksi harga properti, linear regression, boosted tree regressor, XGBoost

I. Latar Belakang & Pemahaman Bisnis

Properti merupakan segala sesuatu yang dimiliki secara sah oleh seseorang atau suatu bisnis dengan hak-hak tertentu yang dapat ditegakkan atas barang-barang tersebut [1]. Properti sebagai harta atau aset yang mengacu pada hak kepemilikan atas benda, baik fisik (tanah, bangunan, atau lainnya) maupun non-fisik (hak kekayaan intelektual). Properti merupakan produk yang unik karena nilainya dipengaruhi oleh kondisi alami (lokasi dan lingkungan) dan kondisi buatan yang dikembangkan oleh pengembang seperti fasilitas, keamanan, dan desain bangunan [2]

Zaman yang terus berkembang, sejalan dengan meningkatnya penduduk di dunia. Penduduk yang memerlukan tempat tinggal untuk bertahan hidup dan ditinggali selama bertahun-tahun. Namun, semakin bertambah penduduk, semakin berkurang lokasi tempat tinggal atau tanah yang tersedia. Hal ini menyebabkan kenaikan terus-menerus akan permintaan terhadap properti, khususnya rumah tinggal [3]. Akan tetapi, diketahui bahwa tidak banyak calon pembeli akan pengetahuan mengenai harga tanah dan bangunan. Ketidaktahuan informasi tersebut mengakibatkan banyak yang menjual atau membeli properti. Jika pembeli properti membeli dengan harga diatas pasaran, mereka harus mengeluarkan sumber daya lebih dari yang seharusnya [3].

Maka dari itu, diperlukannya prediksi harga rumah. Prediksi harga rumah telah menjadi fokus utama dalam penelitian *real estate* [4]. Dengan pertumbuhan ekonomi yang pesat dan urbanisasi yang terus meningkat, mengakibatkan pasar properti yang kompleks [4]. Hal tersebut menimbulkan sebuah tantangan untuk memprediksi harga rumah. Oleh karena itu, prediksi yang didapatkan melalui bantuan *Machine Learning* dengan memeriksa data masa lalu dan tren pasar untuk memprediksi harga aset dan mengoptimalkan strategi perdagangan [5].

Dengan adanya ketidakpastian harga properti menjadi permasalahan penting dalam industri real estate [6]. Kurangnya informasi yang akurat dan transparan mengenai nilai pasar properti dapat meningkatkan risiko kesalahan dalam pengambilan keputusan, baik bagi pembeli, penjual, maupun investor. Oleh karena itu, diperlukan suatu pendekatan yang mampu membantu memprediksi harga properti secara objektif dan berbasis data.

Pendekatan *Machine Learning* banyak digunakan karena kemampuannya dalam mempelajari pola dari data historis dan tren pasar guna menghasilkan prediksi harga yang lebih akurat [6]. Linear Regression dengan kesederhanaannya dan kemampuannya dalam memodelkan hubungan antara variabel independen dan variabel dependen [6]. Namun, model ini memiliki keterbatasan dalam menangkap hubungan non-linear antar variabel. Oleh karena itu, penelitian ini juga menerapkan *Boosted Tree Regressor* yang mampu memodelkan hubungan kompleks dan non-linear melalui pendekatan *ensemble learning*. Dengan menggunakan metrik evaluasi, dapat diketahui kinerja kedua model untuk menentukan model yang paling optimal dalam prediksi harga properti.

II. Tinjauan Teoritis

A. Big Data Analytics

Big Data merupakan sekumpulan data dengan karakteristik 3V (*Volume, Variety, Velocity, Veracity, Value*). *Big Data Analytics* adalah proses analisis *Big Data* ini untuk menemukan pola tersembunyi, tren, atau wawasan strategis [7]. *Big Data Analytics* memanfaatkan *machine learning* dan *predictive analytics* untuk mengolah data terstruktur maupun tidak terstruktur secara efisien [7]. Hal tersebut bertujuan agar dapat meningkatkan efisiensi dan keefektifan kinerja bisnis melalui pengambilan keputusan dengan tepat yang berdasarkan pada data, bukan asumsi subjetif.

Konsep *Big Data Analytics* menjadi landasan dalam mendukung proses prediksi harga properti dengan pola yang kompleks. Dengan pendekatan analitik berbasis data untuk mengolah dan menganalisis informasi tersebut secara sistematis, dapat menghasilkan prediksi harga properti yang lebih akurat guna mendukung pengambilan keputusan bagi pembeli, penjual, dan pelaku bisnis properti.

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

B. Data Science Framework

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) terdiri dari 6 tahap, dimulai dari Business Understanding dalam memahami penyebab dan tujuan, dan kebutuhan bisnis [9]. Kedua, *Data Understanding* untuk mengidentifikasi karakteristik data. Setelah dipahami, dilakukan *Data Preparation* dengan membersihkan data dan pemilihan fitur agar siap digunakan dalam pemodelan. Lanjut, *Modeling* dengan membangun dan menguji model menggunakan algoritma tertentu. Kemudian, *Evaluation* dalam menilai hasil dan menentukan algoritma terbaik menggunakan metrik. Terakhir, *Deployment* yang mengimplementasikan hasil pemodelan untuk digunakan di kehidupan nyata dan kebutuhan bisnis [9].

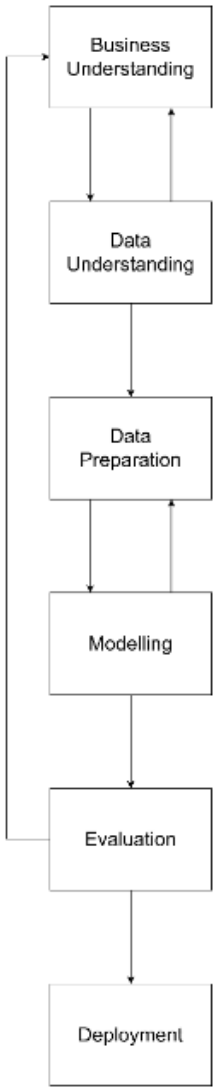


Fig. 1. Tahapan-Tahapan CRISP-DM

C. Exploratory Data Analysis

Exploratory Data Analysis (EDA) merupakan proses awal dalam analisis data yang bertujuan memahami struktur, pola, dan kualitas data sebelum masuk ke tahap pemodelan [10]. Melalui EDA, dapat mengetahui tipe data, mendeteksi nilai hilang, anomali, evaluasi distribusi fitur numerik dan kategorikal, serta mengidentifikasi hubungan antar variabel menggunakan visualisasi dan statistik sederhana. Hal ini bertujuan untuk memastikan bahwa data telah bersih, konsisten, dan siap digunakan sehingga model yang dibangun menjadi lebih akurat dan terpercaya [10].

D. Machine Learning

Machine learning merupakan algoritma dengan rumus matematis terhadap system dalam mendeteksi pola dari data [11]. Semakin tepat algoritma yang digunakan, semakin baik kualitas keputusan yang dihasilkan. *Machine learning* mampu menangani data berskala besar yang kompleks dan memiliki hubungan non-linear antar variable [11]. Prediksi akan suatu permasalahn yang kompleks seperti data yang selalu berubah-ubah seiring zaman berkembang, maka diperlukan pendekatan yang menghasilkan tingkat akurasi secara konsisten. Keunggulan-keunggulan tersebut menjadikan machine learning sebagai pendekatan yang efektif dalam meningkatkan kualitas prediksi dan mendukung pengambilan keputusan berbasis data [11].

Prediksi properti menggunakan pendekatan machine learning relevan untuk menjawab permasalahan ketidakpastian harga yang dihadapi oleh pembeli, penjual, dan investor. Ketidakpastiaan harga properti akibat berbagai karakteristik fisik yang saling berinteraksi secara kompleks. Permasalahan tersebut dapat diatasi oleh machine learning yang mampu menghasilkan estimasi harga properti secara akurat.

E. Linear Regression

Linear Regression atau regresi linear merupakan salah satu model machine learning dengan hubungan antara satu atau lebih variabel independen (X) dan variabel dependen (*Y*) [6]. Model ini terkenal akan kesederhanaannya karena bisa meminimalkan *Root Mean Squared Error* (RMSE) untuk menemukan garis terbaik yang dapat menjelaskan hubungan antara variabel [6]. Berikut rumus dari *Mutiple Linear Regression* pada Fig 2 [17].

$$Y = a + b_1X_1 + b_2X_2 + \cdots + b_nX_n$$

Fig. 2. Rumus Mutiple Linear Regression

F. Boosted Tree Regressor

Boosted Tree Regressor diimplementasikan yang berbasis pada library XGBoost di *Google Big Query Machine Learning* [15]. XGBoost (*Extreme Gradient Boosting*) adalah implementasi yang dioptimalkan dari *Gradient Boosting*, yang dimana model dibangun secara bertahap dalam memperbaiki kesalahan dari model sebelumnya [4]. XGBoost sebagai teknik secara paralel dalam membangun pohon keputusan secara efisien dengan peningkatan berdasarkan *Gradient Boosting Decision Tree* (GBDT) [18]. Keputusan diwakili oleh *leaf node* di dalam pohon. Dalam XGBoost, prediksi akhir diperoleh dengan menambahkan prediksi yang dibuat oleh model baru ke residual model sebelumnya [18]. Berikut langkah-lanngkah dilengkapi dengan rumus XGBoost dalam membangun pohon, yaitu sebagai berikut [19].

1) Melakukan inisialisasi probabilitas pada prediksi awal Pr_i^1 di mana i=1,2,…n
2) Menghitung residual

$$Residual_i^t = Y_i - Pr_i^r$$

Fig. 3. Rumus Menghitung Residual

3) Menghitung nilai *similarity*

$$SS_{mode} = \frac{(\sum Residual_i)^2}{\sum[Pr_i^t \times (1 - Pr_i^t)] + \lambda}$$

Fig. 4. Rumus Menghitung *Similarity*

4) Menghitung nilai *gain*

$$Entropi(S) = \sum_{i=1}^{n} - p_i \log_2 (p_i)$$

Fig. 5. Rumus Menghitung *Gain*

5) Menghitung nilai *leaf output*

$$Output(A)_i = \frac{\sum Residual_i}{\sum[Pr_i^t \times (1 - Pr_i^t)] + \lambda}$$

Fig. 6. Rumus Menghitung *Leaf Output*

6) Menghitung nilai *log odds*

$$Log\ odds_i^t = log\left(\frac{Pr_i^t}{1 - Pr_i^t}\right)$$

Fig. 7. Rumus Menghitung *Log Odds*

7) Memperbarui nilai probabilitas

$$Pr_i^{t+1} = \log(odds_i^t) + (\eta \times output(A)_i)$$

Fig. 8. Rumus Menghitung Probilitas

8) Menormalisasi nilai probabilitas menggunakan fungsi *sigmoid* biner

$$Sigmoid(Pr_i^{t+1}) = \frac{exp^{Pr_i^{t+1}}}{1 + exp^{Pr_i^{t+1}}}$$

Fig. 9. Rumus Menghitung Probabilitas Fungsi *Sigmoid* Biner

9) Ulangi langkah-langkah dari langkah 2 sampai dengan 8
10) Melakukan evaluasi kinerja algoritma klasifikasi

G. Performance Measures

Evaluasi untuk mengukur sejauh mana model dapat memprediksi harga rumah secara akurat, dengan menggunakan RMSE dan R^2. Dari hasil evaluasi tersebut, dapat diketahui tingkat persentase error yang dilihat dari perbedaan nilai asli dengan nilai prediksi [2].

- RMSE (*Root Mean Squared Error*) yang menghitung rata-rata kesalahan prediksi dalam satuan yang sama dengan variabel target, di mana nilai yang lebih kecil menunjukkan akurasi model yang lebih tinggi [6]. Berikut rumus dari RMSE pada Fig 10 [16].

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_{\text{true},i} - y_{\text{pred},i})^2}$$

Fig. 10. Rumus RMSE

- R^2 (*R-squared*) sebagai koefisien determinasi untuk melihat seberapa baik akan hasil prediksinya [12]. R^2 yang mengukur seberapa besar variasi variabel target dapat dijelaskan oleh model, yang dimana nilai yang mendekati 1 menunjukkan performa model yang lebih baik [6]. Berikut rumus dari R^2 pada Fig 11 [16].

$$R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}}$$

Fig. 11. Rumus R^2

H. Previous Research

Beberapa penelitian sebelumnya menunjukkan bahwa *Linear Regression* masih sering digunakan dalam prediksi harga properti karena kesederhanaan dan kemudahan interpretasinya. Penelitian oleh Palupi [13] membandingkan *Linear Regression* dengan *Neural Network* dan menemukan bahwa *Linear Regression* mampu memberikan performa prediksi yang lebih optimal dengan tingkat kesalahan yang relatif rendah. Hasil ini menunjukkan bahwa dataset dengan hubungan variabel yang relatif sederhana, model linear masih cukup efektif dan stabil.

Sama halnya oleh penelitian Hallan dan Fajri [6] juga menyatakan bahwa *Linear Regression* dapat menghasilkan akurasi yang baik dalam memprediksi harga rumah dengan pemilihan variabel yang relevan. Penelitian ini menegaskan bahwa model sederhana yang mempermudah dalam analisis hubungan antar variabel.

Namun demikian, keterbatasan *Linear Regression* ketika jumlah variabel semakin banyak dan hubungan antar variabel menjadi lebih kompleks. Penelitian oleh Hibatulloh dkk. [4] yang melakukan analisis komparatif pada prediksi harga rumah di Bandung menunjukkan bahwa *Linear Regression* menghasilkan performa terendah dibandingkan metode *ensemble learning*, seperti *Boosted Tree*. Hal ini disebabkan oleh ketidakmampuan model linear dalam menangkap hubungan non-linear dan kompleks antara karakteristik fisik dan lokasi yang beragam.

Hibatulloh dkk. [4] juga mempertegas bahwa metode *ensemble learning* tidak hanya unggul dalam akurasi, tetapi juga mampu menangani heterogenitas data properti yang tinggi dan variasi harga yang ekstrem. Hal ini menunjukkan bahwa seiring meningkatnya kompleksitas data dan kebutuhan akan prediksi yang lebih presisi, model yang yang berbasis pada *ensemble learning* menjadi pemilihan model

alternatif yang lebih unggul dibandingkan model linear konvensional [4].

Berdasarkan penelitian-penelitian terdahulu tersebut, dapat disimpulkan bahwa meskipun *Linear Regression* masih relevan untuk kasus sederhana, terdapat *research gap* dalam pemilihan model yang mampu menangkap pola non-linear dan kompleksitas data properti secara lebih optimal. Oleh karena itu, penelitian ini melakukan perbandingan antara *Linear Regression* dan *Boosted Tree Regressor* untuk mengevaluasi kinerja efektivitas kedua model dalam memprediksi harga properti berdasarkan karakteristik fisik dan lokasi.

III. METODOLOGI PENELITIAN

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) merupakan metodologi yang umum digunakan oleh tim ilmu data untuk membantu proses analisis data secara terstruktur dan sistematis dari tahap awal hingga akhir [8]. *Framework* yang terstandarisasi dan terstuktur, dapat disesuaikan terhadap perubahan data, teknologi, dan kebutuhan bisnis. Dengan demikian, CRISP-DM memastikan bahwa proses [8]. Analisis data tidak hanya fokus pada aspek teknis, tetapi juga selaras dengan tujuan bisnis yang ingin dicapai. Metodologi ini terdiri dari 6 tahapan yang fleksibel, yang dimana bisa (dan mungkin harus) bolak-balik antar tahapan [9].

A. Business Understanding

Tahap pertama dimulai dari *Business Understanding* dalam memahami penyebab dan tujuan, dan kebutuhan bisnis. Sebagai tahapan pertama dalam CRISP-DM untuk memahami kebutuhan dan tujuan bisnis secara mendalam [2]. Pada tahap ini dilakukan dengan mencari identifikasi, penyebab, tujuan, dan dampak dari suatu permasalahan. Dengan memahami permasalahan yang sedang dianalisa, dapat mempermudah untuk mencapai hasil yang diinginkan dan tujuan dapat terealisasikan.

Properti merupakan aset yang dimiliki secara sah, baik dalam bentuk fisik seperti tanah dan bangunan maupun non-fisik, yang nilainya dipengaruhi oleh kondisi alami seperti lokasi dan lingkungan, dan kondisi buatan yang dikembangkan oleh pengembang seperti fasilitas, keamanan, dan desain bangunan [1], [2]. Seiring dengan perkembangan zaman dan pertumbuhan penduduk, permintaan akan tempat tinggal terus meningkat, sedangkan ketersediaan lahan semakin terbatas. Kondisi ini menyebabkan permintaan properti, khususnya rumah tinggal, terus mengalami peningkatan [3].

Namun, masih banyak calon pembeli maupun penjual yang memiliki keterbatasan pengetahuan mengenai harga pasar properti. Kurangnya informasi yang akurat dapat menyebabkan kesalahan dalam transaksi, seperti pembelian properti dengan harga di atas nilai pasar yang seharusnya [3]. Dengan pertumbuhan ekonomi dan urbanisasi yang pesat, pasar properti menjadi semakin kompleks, sehingga prediksi harga rumah menjadi tantangan tersendiri dan telah menjadi fokus utama dalam berbagai penelitian *real estate* [4]. Ketidakpastian harga properti juga meningkatkan risiko dalam pengambilan keputusan bagi pembeli, penjual, maupun investor [6].

Untuk mengatasi permasalahan tersebut, pendekatan *Machine Learning* banyak digunakan karena kemampuannya dalam mempelajari pola dari data historis dan tren pasar guna menghasilkan prediksi harga yang lebih akurat [5], [6]. *Linear Regression* sering digunakan karena kesederhanaannya dan kemampuannya dalam memodelkan hubungan antara variabel independen dan dependen [6], namun memiliki keterbatasan dalam menangkap hubungan non-linear. Oleh karena itu, penelitian ini juga menerapkan *Boosted Tree Regressor* yang mampu memodelkan hubungan kompleks melalui pendekatan *ensemble learning* dan mengevaluasi kinerja kedua model menggunakan metrik evaluasi untuk menentukan model yang paling optimal dalam prediksi harga properti.

B. Data Understanding

Kedua, *Data Understanding* untuk mengidentifikasi karakteristik [9]. Sebagai tahapan yang bertujuan untuk memahami karakteristik data. Pada tahap ini dilakukan kegiatan berupa mengumpulkan, mengidentifikasi, menganalisis kumpulan data dan memverifikasi kualitas data yang dapat membantu untuk mencapai tujuan proyek [2]. Tahapan data understanding merupakan tahapan penting agar peneliti dapat memahami karakteristik dataset sebelum masuk ke dalam tahapan *data preparation* dan pemodelan lebih lanjut.

Dataset yang digunakan dalam penelitian ini diperoleh dari platform *Kaggle* yang berisikan data penjualan property di Melbourne, Australia [16]. Dataset tersebut terdiri dari 18.396 baris dan 19 kolom. Pada tahap ini, data mentah dimuat, diperiksa, dan disimpan untuk proses selanjutnya [5]. Pemeriksaan untuk mengetahui nilai yang hilang (*missing value*), nilai yang terduplikasi (*redundant*), ataupun pencilan (*outlier*). Pengetahuan tersebut wajib diketahui untuk dijadikan dasar dalam pengambilan keputusan pada proses persiapan data selanjutnya [11].

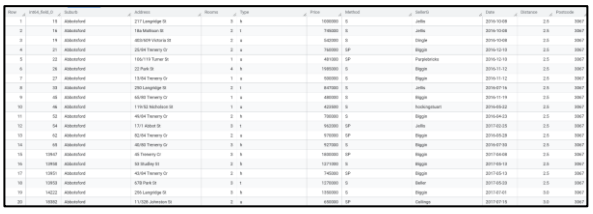


Fig. 12. Dataset Mentah

Setelah itu, dalam pemahaman dari *Business Understanding* menyatakan bahwa penelitian ini hanya berfokus pada prediksi harga properti berdasarkan karakteristik fisik, sehingga diperlukannya *Feature Engineering* untuk mengurangi kompleksitas data yang tidak berhubungan, yang akan diproses di tahap *Data Preparation*.

Setelah dilakukan *feature engineering* dan *handling missing value* untuk mendukung proses pemodelan yang optimal, tahap selanjutnya adalah EDA untuk mengeksplorasi karakteristik data secara lebih mendalam.

Berdasarkan hasil EDA menggunakan visualisasi *line chart*, variabel *Landsize* menunjukkan peningkatan harga properti yang konsisten. Rata-rata harga properti cenderung meningkat seiring bertambahnya luas tanah. Sama seperti pada variabel *Building Area* dengan harga properti meningkat secara stabil. Hal ini menunjukkan bahwa semakin besar ukuran, semakin naik harga.

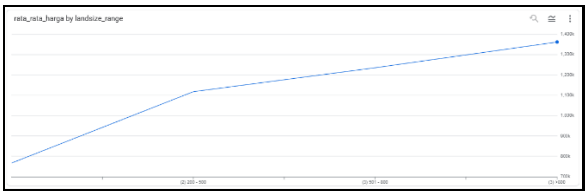


Fig. 13. Tren Rata-Rata Harga Properti Berdasarkan *Land Size*

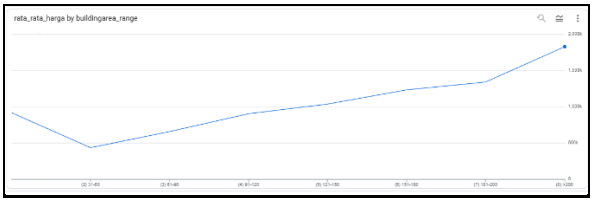


Fig. 14. Tren Rata-Rata Harga Properti Berdasarkan *Building Area*

Sebaliknya, variabel *Distance* menunjukkan kecenderungan penurunan harga. Semakin jauh jarak properti dari pusat kota, rata-rata harga properti semakin menurun. Sama seperti pada variabel *YearBuilt* dengan tahun pembangunan yang lebih lama cenderung memiliki harga yang lebih rendah, meskipun terdapat sedikit kenaikan pada periode tertentu (sekitar tahun 1970–1990). Hal ini menunjukkan bahwa usia bangunan yang lebih tua berkorelasi negatif dengan harga properti.

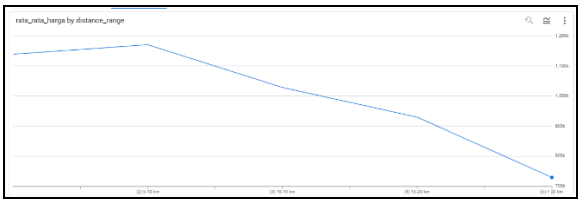


Fig. 15. Tren Rata-Rata Harga Properti Berdasarkan *Distance*

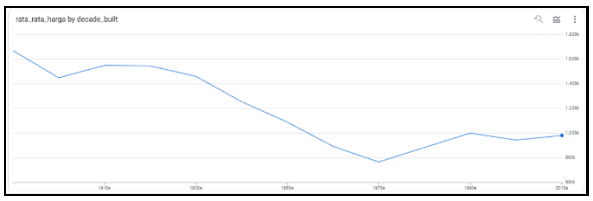


Fig. 16. Tren Rata-Rata Harga Properti Berdasarkan *YearBuilt*

Sementara itu, variabel *Rooms*, *Bedroom*, *Bathroom*, dan *Car* tidak menunjukkan pola linear yang konsisten terhadap harga properti. Hal ini mengindikasikan bahwa bertambahnya jumlah kamar tidur, kamar mandi, atau garasi tidak menentukan adanya peningkatan harga.

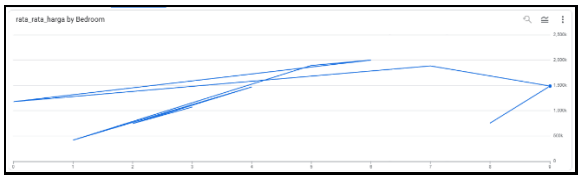


Fig. 17. Tren Rata-Rata Harga Properti Berdasarkan *Bedroom*

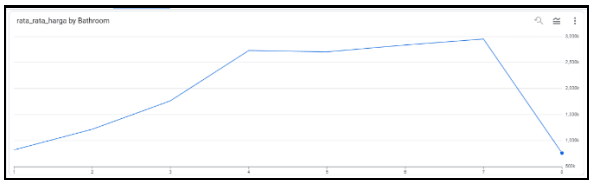


Fig. 18. Tren Rata-Rata Harga Properti Berdasarkan *Bathroom*

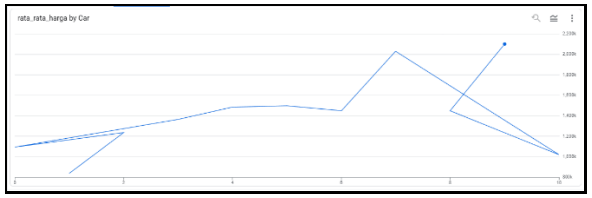


Fig. 19. Tren Rata-Rata Harga Properti Berdasarkan *Car*

C. *Data Preparation*

Setelah dipahami, dilakukan *Data Preparation* dengan membersihkan data dan pemilihan fitur agar siap digunakan dalam pemodelan. Sebagai tahapan untuk menyiapkan data yang akan digunakan pada proses pemodelan. *Preprocessing data* diperlukan untuk memastikan bahwa data telah sesuai agar dapat menghasilkan analisis yang tepat [22].

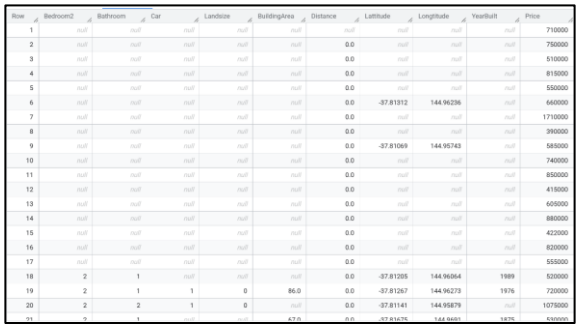
Setelah memahami data yang dimiliki dan memerlukan *Feature Engineering* untuk menyesuaikan dengan tujuan penelitian, sehingga hanya menggunakan 7 variabel utama, yaitu karakteristik fisik (*Rooms, Bedroom, Bathroom, Car, Landsize, BuildingArea, YearBuilt*), lokasi (*Distance, Latitude, Longitude)*, dan *Price.*

TABLE I. VARIABLE DETAILS

Nama Variable	Tipe Data	Deskripsi
Price	*Integer*	Harga jual properti dalam dolar Australia (AUD)
Bedroom	*Integer*	Jumlah kamar tidur
Bathroom	*Integer*	Jumlah kamar mandi
Car	*Integer*	Jumlah garansi
Landsize	*Integer*	Luas tanah (m^2) properti
BuildingArea	*Float*	Total luas bangunan (m^2) properti
Distance	*Float*	Jarak dari properti ke pusat bisnis
Latitude	*Float*	Titik koordinat lintang
Longitude	*Float*	Titik koordinat bujur
YearBuilt	*Integer*	Tahun bangunan dibangun

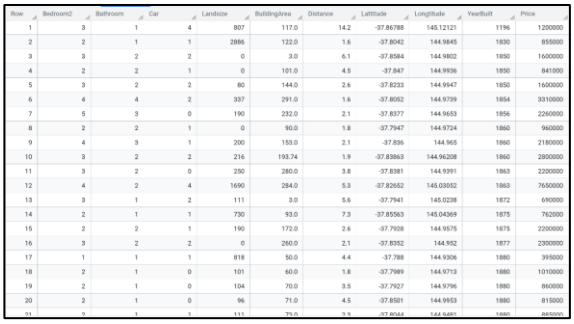
Price sebagai variabel dependen (*target*) untuk harga jual properti, sedangkan *Bedroom, Bathroom, Car, Landsize, BuildingArea, Distance, Latitude, Longitude,* dan *YearBuilt* sebagai variabel independen. Pemahaman data untuk menentukan variabel yang relevan untuk proses pemodelan. Dengan demikian, *Feature Engineering* membantu dalam

meningkatkan efisiensi dan akurasi proses pelatihan model dan membangun variabel baru yang lebih bermakna [5].



Row	Bedroom2	Bathroom	Car	Landsize	BuildingArea	Distance	Lattitude	Longtitude	YearBuilt	Price
1	null	null	null	null	null	null	null	null	null	710000
2	null	null	null	null	null	0.0	null	null	null	750000
3	null	null	null	null	null	0.0	null	null	null	510000
4	null	null	null	null	null	0.0	null	null	null	815000
5	null	null	null	null	null	0.0	null	null	null	550000
6	null	null	null	null	null	0.0	-37.81312	144.96236	null	660000
7	null	null	null	null	null	0.0	null	null	null	1710000
8	null	null	null	null	null	0.0	null	null	null	390000
9	null	null	null	null	null	0.0	-37.81069	144.95743	null	585000
10	null	null	null	null	null	0.0	null	null	null	740000
11	null	null	null	null	null	0.0	null	null	null	850000
12	null	null	null	null	null	0.0	null	null	null	415000
13	null	null	null	null	null	0.0	null	null	null	605000
14	null	null	null	null	null	0.0	null	null	null	880000
15	null	null	null	null	null	0.0	null	null	null	422000
16	null	null	null	null	null	0.0	null	null	null	820000
17	null	null	null	null	null	0.0	null	null	null	555000
18	2	1	null	null	null	0.0	-37.81205	144.96064	1989	520000
19	2	1	1	0	86.0	0.0	-37.81267	144.96273	1976	720000
20	2	2	1	0	null	0.0	-37.81141	144.95879	null	1075000
21	2	1	null	null	47.0	0.0	-37.81675	144.9481	1875	530000

Fig. 20. Dataset Setelah *Feature Engineering*

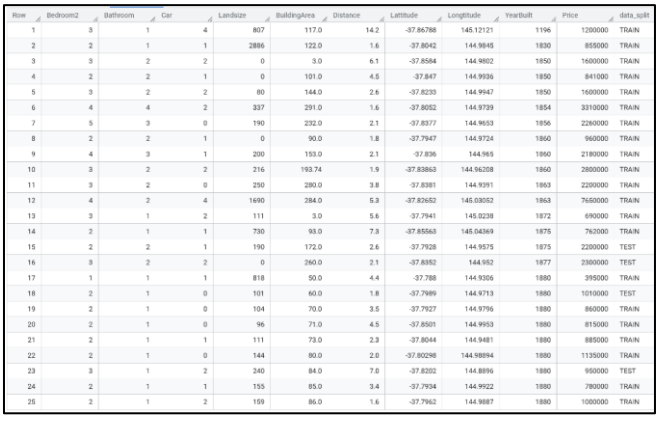


Row	Bedroom2	Bathroom	Car	Landsize	BuildingArea	Distance	Lattitude	Longtitude	YearBuilt	Price
1	3	1	4	807	117.0	14.2	-37.86788	145.12121	1196	1200000
2	2	1	1	2886	122.0	1.6	-37.8042	144.9845	1830	855000
3	3	2	2	0	3.0	6.1	-37.8584	144.9802	1850	1600000
4	2	2	1	0	101.0	4.5	-37.847	144.9936	1850	841000
5	3	2	2	80	144.0	2.6	-37.8233	144.9947	1850	1600000
6	4	4	2	337	291.0	1.6	-37.8052	144.9739	1854	3310000
7	5	3	0	190	232.0	2.1	-37.8377	144.9653	1856	2260000
8	2	2	1	0	90.0	1.8	-37.7947	144.9724	1860	960000
9	4	3	1	200	153.0	2.1	-37.836	144.965	1860	2180000
10	3	2	2	216	193.74	1.9	-37.83863	144.96208	1860	2800000
11	3	2	0	250	280.0	3.8	-37.8381	144.9391	1863	2200000
12	4	2	4	1690	284.0	5.3	-37.82652	145.03052	1863	7650000
13	3	1	2	111	3.0	5.6	-37.7941	145.0238	1872	690000
14	2	1	1	730	93.0	7.3	-37.85563	145.04369	1875	762000
15	2	2	1	190	172.0	2.6	-37.7928	144.9575	1875	2200000
16	3	2	2	0	260.0	2.1	-37.8352	144.952	1877	2300000
17	1	1	1	818	50.0	4.4	-37.788	144.9306	1880	395000
18	2	1	0	101	60.0	1.8	-37.7989	144.9713	1880	1010000
19	2	1	0	104	70.0	3.5	-37.7927	144.9796	1880	860000
20	2	1	0	96	71.0	4.5	-37.8501	144.9953	1880	815000
21	2	1	1	111	73.0	2.3	-37.8044	144.9481	1880	885000

Fig. 21. Dataset Setelah *Handling Missing Value*

Pada tahap ini juga, dilakukan dataset dibagi menjadi 2 bagian (*data splitting*) menjadi 80% data pelatihan (*data train*) dan 20% data pengujian (*data test*) guna memastikan evaluasi model yang objektif dan reliabel [4]. Data pelatihan untuk membangun model prediksi, sedangkan data pengujian untuk mengevaluasi kinerja model yang telah dibangun [4].

Pada Fig. 22 menunjukkan hasil *data splitting* yang dilakukan, di mana setiap baris data telah diberi label *TRAIN* atau *TEST* pada kolom *data_split*. Pembagian ini memastikan bahwa proses evaluasi model dilakukan pada data yang independen dari proses pelatihan, sehingga hasil evaluasi yang diperoleh lebih valid dan tidak *bias*.



Row	Bedroom2	Bathroom	Car	Landsize	BuildingArea	Distance	Lattitude	Longtitude	YearBuilt	Price	data_split
1	3	1	4	807	117.0	14.2	-37.86788	145.12121	1196	1200000	TRAIN
2	2	1	1	2886	122.0	1.6	-37.8042	144.9845	1830	855000	TRAIN
3	3	2	2	0	3.0	6.1	-37.8584	144.9802	1850	1600000	TRAIN
4	2	2	1	0	101.0	4.5	-37.847	144.9936	1850	841000	TRAIN
5	3	2	2	80	144.0	2.6	-37.8233	144.9947	1850	1600000	TRAIN
6	4	4	2	337	291.0	1.6	-37.8052	144.9739	1854	3310000	TRAIN
7	5	3	0	190	232.0	2.1	-37.8377	144.9653	1856	2260000	TRAIN
8	2	2	1	0	90.0	1.8	-37.7947	144.9724	1860	960000	TRAIN
9	4	3	1	200	153.0	2.1	-37.836	144.965	1860	2180000	TRAIN
10	3	2	2	216	193.74	1.9	-37.83863	144.96208	1860	2800000	TRAIN
11	3	2	0	250	280.0	3.8	-37.8381	144.9391	1863	2200000	TRAIN
12	4	2	4	1690	284.0	5.3	-37.82652	145.03052	1863	7650000	TRAIN
13	3	1	2	111	3.0	5.6	-37.7941	145.0238	1872	690000	TRAIN
14	2	1	1	730	93.0	7.3	-37.85563	145.04369	1875	762000	TRAIN
15	2	2	1	190	172.0	2.6	-37.7928	144.9575	1875	2200000	TEST
16	3	2	2	0	260.0	2.1	-37.8352	144.952	1877	2300000	TEST
17	1	1	1	818	50.0	4.4	-37.788	144.9306	1880	395000	TRAIN
18	2	1	0	101	60.0	1.8	-37.7989	144.9713	1880	1010000	TEST
19	2	1	0	104	70.0	3.5	-37.7927	144.9796	1880	860000	TRAIN
20	2	1	0	96	71.0	4.5	-37.8501	144.9953	1880	815000	TRAIN
21	2	1	1	111	73.0	2.3	-37.8044	144.9481	1880	885000	TRAIN
22	2	1	0	144	80.0	2.0	-37.80298	144.98894	1880	1135000	TRAIN
23	3	1	2	240	84.0	7.0	-37.8202	144.8896	1880	950000	TEST
24	2	1	1	155	85.0	3.4	-37.7934	144.9922	1880	780000	TRAIN
25	2	1	2	159	86.0	1.6	-37.7962	144.9887	1880	1080000	TRAIN

Fig. 22. Data Spliting

D. Modelling

Lanjut, *Modelling* dengan membangun dan menguji model menggunakan algoritma yang ditentukan [9]. Sebagai tahapan pembelajaran bagi mesin yang digunakan untuk mempelajari pola dan hubungan antara variabel input dengan variabel target berdasarkan data historis. Model yang dibangun akan diuji menggunakan data yang belum pernah dilihat sebelumnya untuk menilai kemampuan generalisasinya [9]. Tahapan ini bertujuan untuk menghasilkan model yang mampu memberikan prediksi yang akurat serta stabil, sehingga dapat digunakan sebagai dasar dalam pengambilan keputusan berbasis data.

TABLE II. HASIL NILAI PREDIKSI HARGA MENGGUNAKAN LINEAR REGRESSION

Harga Aktual (AUD)	Harga Prediksi (AUD)
2.200.000	572.282
2.300.000	1.016.116
1.010.000	99.667
950.000	230.553
485.000	161.226
910.000	251.459
1.263.000	454.952
1.635.000	372.079
2.300.000	939.525
2.600.000	937.129
1.410.000	423.604
1.750.000	662.020
1.500.000	1.485.061
812.000	163.587

Berdasarkan table II, hasil nilai prediksi oleh pemodelan *Linear Regression* menunjukkan bahwa banyak yang jauh berbeda dari harga aktual, ada yang terlalu tinggi dan ada yang terlalu rendah. Hal ini menunjukkan bahwa model ini kurang bisa dalam menangkap pola hubungan yang kompleks antara variabel karakteristik fisik, lokasi, dan harga properti.

TABLE III. HASIL NILAI PREDIKSI HARGA MENGGUNAKAN BOOSTED TREE REGRESSOR (XGBOOST)

Harga Aktual (AUD)	Harga Prediksi (AUD)
2.200.000	1.659.014
2.300.000	2.177.485
1.010.000	898.722
950.000	1.020.629
485.000	815.316
910.000	742.469
1.263.000	1.230.719
1.635.000	1.278.676
2.300.000	2.946.979
2.600.000	1.812.462
1.410.000	1.248.898
1.750.000	2.011.655
1.500.000	2.691.024
812.000	1.860.722

Berbeda dengan *Linear Regression*, pada table III, hasil nilai prediksi oleh pemodelan *Boosted Tree Regressor*

(XGBoost) menunjukkan bahwa nilai prediksi lebih mendekati harga aktual. Selisih antara harga aktual dan harga prediksi cenderung lebih kecil dan lebih stabil. Hal ini membuktikan bahwa model ini berhasil menangkap pola non-linear dan bisa dengan data variabel yang kompleks.

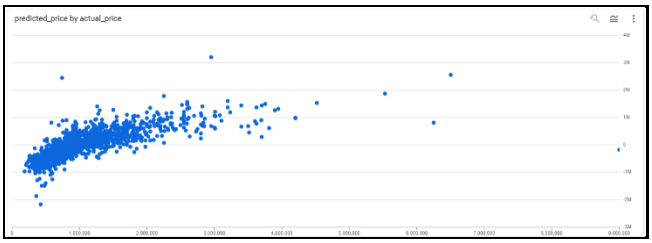


Fig. 23. Scatter Plot Actual Price vs Predicted Price (Linear Regression)

Pada scatter plot *Linear Regression*, sebagian besar titik data mengikuti pola diagonal dari kiri bawah ke kanan atas, berarti hubungan positif antara harga aktual dan harga prediksi. Tapi, sebaran titik masih cukup lebar, sehingga model ini kurang akurat dalam memprediksi harga yang kesulitan menangkap hubungan yang lebih kompleks dan non-linear antar variabel.

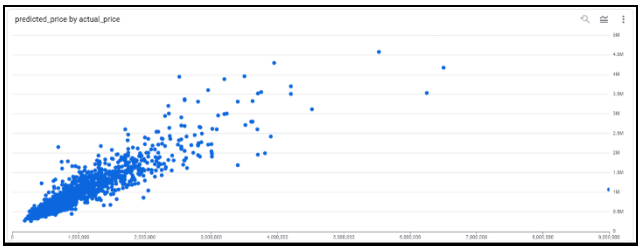


Fig. 24. Scatter Plot Actual Price vs Predicted Price (Boosted Tree Regressor (XGBoost))

Berbeda dengan *Linear Regression*, scatter plot pada *Boosted Tree Regressor* menunjukkan pola yang lebih rapat mengikuti garis diagonal dibandingkan Linear Regression. Titik-titik prediksi tersebar lebih dekat dengan nilai aktual, baik pada harga rendah, menengah, maupun tinggi. Jadi model ini stabil dan konsisten dalam menghasilkan prediksi.

E. Evaluation

Kemudian, Evaluation dalam menilai hasil dengan menggunakan metrik. Sebagai tahapan yang menilai seberapa baik kinerja model dalam melakukan prediksi. Penilaian dilakukan menggunakan metrik evaluasi seperti RMSE yang menunjukkan seberapa besar rata-rata kesalahan prediksi dalam satuan harga, dan R^2 yang menggambarkan seberapa besar variasi harga properti dapat dijelaskan oleh model [6]. Nilai RMSE yang lebih kecil dan R^2 yang mendekati 1 menunjukkan performa model yang lebih baik dalam memprediksi harga properti.

Setelah melakukan proses pelatihan model menggunakan algoritma *Linear Regression* dan *Boosted Tree Regressor* (XGBoost), lanjut dilakukan evaluasi untuk mengukur tingkat akurasi dan kesalahan prediksi dari masing-masing model. Metrik evaluasi yang digunakan adalah R^2 dan RMSE. Hasil perbandingan kedua model disajikan dalam Tabel IV.

TABLE IV. PERBANDINGAN EVALUASI SETIAP MODEL

No	Model	R^2	RMSE
1	*Linear Regression*	59 %	0.13
2	*Boosted Tree Regressor (XGBoost)*	79 %	0.04

F. Deployment

Terakhir, *Deployment* yang mengimplementasikan hasil pemodelan dan diintegrasikan ke dalam lingkungan bisnis, sehingga dapat digunakan dalam aplikasi dunia nyata [9]. Sebagai tahapan akhir dalam proses pengembangan model yang mengimplementasikan model yang telah dievaluasi ke dalam lingkungan bisnis. Model yang sudah memiliki performa terbaik dapat digunakan untuk membantu pengambilan keputusan, misalnya dalam memperkirakan harga properti secara otomatis berdasarkan karakteristik tertentu.

IV. HASIL DAN PEMBAHASAN

Hasil prediksi *Linear Regression* menunjukkan banyak perbedaan yang cukup besar antara harga aktual dan harga prediksi, baik terlalu tinggi maupun terlalu rendah, sehingga model ini kurang mampu menangkap hubungan kompleks antara karakteristik fisik, lokasi, dan harga properti. Sebaliknya, hasil prediksi *Boosted Tree Regressor* (XGBoost) menunjukkan nilai yang lebih mendekati harga aktual dengan selisih yang lebih kecil dan stabil. Hal ini membuktikan bahwa *Boosted Tree Regressor* (XGBoost) lebih efektif dalam memodelkan pola non-linear dan menangani variabel yang kompleks.

Visualisasi dengan scatter plot *Linear Regression* memperlihatkan pola hubungan positif antara harga aktual dan prediksi, namun sebaran titik yang masih cukup lebar menunjukkan keterbatasan model dalam menangkap hubungan non-linear. Berbeda dengan *Boosted Tree Regressor* (XGBoost) menunjukkan titik-titik yang lebih rapat mengikuti garis diagonal, menandakan prediksi yang lebih akurat dan konsisten. Hal ini menunjukkan bahwa *Boosted Tree Regressor* (XGBoost) memiliki performa yang lebih stabil dibandingkan *Linear Regression*.

Hasil evaluasi metriks menunjukkan perbedaan performa yang signifikan yang di mana model *Boosted Tree Regressor* (XGBoost) lebih unggul dibandingkan model Linear Regression. Model *Linear Regression* hanya menghasilkan nilai R^2 sebesar 59% dengan tingkat kesalahan (RMSE) sebesar 0.13, sedangkan *Boosted Tree Regressor* mencapai nilai R^2 sebesar 79% dengan nilai RMSE yang sangat rendah sebesar 0.04.

Peningkatan akurasi sebesar 20% ini membuktikan bahwa variabel karakteristik fisik dan lokasi properti memiliki keterkaitan yang bersifat non-linear dan kompleks, sehingga algoritma *Boosted Tree Regressor* (XGBoost) mampu menangkap pola interaksi antar variable yang luas dan kompleks dibandingkan garis lurus oleh model linear.

V. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa *Boosted Tree Regressor* (XGBoost) siginifikan lebih efektif sebesar 79% dibandingkan *Linear Regression* hanya 59%. Hal ini menunjukkan bahwa pendekatan *ensemble learning* mampu menangkap hubungan non-linear lebih akurat dibandingkan model linear sederhana. Oleh karena itu, *Boosted Tree Regressor* merupakan pilihan model yang tepat untuk prediksi harga properti berdasarkan karakteristik fisik dan lokasi yang kompleks.

ACKNOWLEDGMENT

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Bapak Iwan Prasetiawan, S.Kom.,M.M., selaku dosen pengampu mata kuliah *Big Data Analytics*, atas bimbingan, arahan, dan dukungan selama proses penyusunan paper ini. Penelitian ini diharapkan dapat menjadi landasan bagi studi lanjutan dalam prediksi harga properti dan mendukung dalam pengambilan keputusan yang tepat dan strategis.

REFERENCES

[1] A. Bloomenthal (2025, Jun. 12) Property: Definition, Types, and Real Estate Examples [Online]. Available at: https://www.investopedia.com/terms/p/property.asp (Accessed: 26 Dec 2025).

[2] Y. Sutanto, B. Al Amin, H. A. Setyadi, and B. E. Purnama, "Prediksi Harga Perumahan Menggunakan Metode Principal Component Analysis dan Random Forest Regresi", *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK)*, vol. 12, no. 6, Des. 2025.

[3] S. Suakanto, A. Christy, V. J. L. Engel, and D. Angela, "Pengembangan Sistem Prediksi Harga Pasar Properti Menggunakan Big Data Platform", Jurnal Telematika, vol. 13, no. 1, 2025.

[4] M. N. Hibatulloh, G. D. Prakoso, A. D. P. Yunus, and T. D. Putra, "Prediksi Harga Rumah di Bandung 2024 Menggunakan Ensemble Learning: Analisis Komparatif dan Interpretabilitas", Jurnal Informatika: Jurnal pengembangan IT, vol. 10, no. 2, 2025.

[5] V. Karpagam, P. Pandiselvam, E. Rajakirubaharan, and K. B. Sabarikumar, "Property Price Prediction using Machine Learning", International Journal of Innovative Research of Science, Engineering and Technology (IJIRSET), vol. 14, no. 4, Apr. 2025.

[6] R. R. Hallan and I. N. Fajri, "Prediksi Harga Rumah menggunakan Machine Learning Algoritma Regresi Linier", Jurnal Teknologi Dan Sistem Informasi Bisnis, vol. 7, no. 1, Jan. 2025.

[7] D. M. Manihuruk, H. Sabillillah, and T. Sutabri, "Big Data Analytics untuk Meningkatkan Pengambilan Keputusan di Industri", *Jurnal Inovasi Teknologi dan Sistem Informasi*, vol. 9, no. 1, 2025.

[8] K. Schultz (2025, Mar. 17) *Understanding the Role of Knowledge Intelligence in the CRISP-DM Framework: A Guide for Data Science Projects* [Online]. Available at: https://enterprise-knowledge.com/understanding-the-role-of-knowledge-intelligence-in-the-crisp-dm-framework-a-guide-for-data-science-projects/ (Accessed: 26 Dec 2025).

[9] A. Rianti, N. W. A. Majid, and A. Fauzi, "CRISP-DM: Metodologi Proyek Data Science", Prosiding Seminar Nasional Teknologi Informasi dan Bisnis (SENATIB), 2023.

[10] J. Johnkutty, S. Haque, and J. Davis T, "Exploratory Data Analysis using Machine learning – Behaviour Based Safety," J. Electrical Syst., vol. 20, no. 7s, pp. 744–754, 2024.

[11] G. Sudarawerti and F. Arif, "Improving Housing Price Prediction with Machine Learning: Evidence from Yogyakarta and Implications for Emerging Urban Markets", International Journal of Management, Entrepreneurship, Social Science and Humanities, vol. 9, no. 1, Okt. 2025.

[12] H. Hakim, D. Kamil, and B. Alatas, "Pendekatan Machine Learning untuk Estimasi Harga Rumah dengan Regresi Linier", Journal of Science and Technology: Alpha, vol. 1, no. 1, pp. 18-22, Jan. 2025.

[13] E. S. Palupi, "House Price Prediction Using Data Mining with Linear Regression and Neural Network Algorithms", *Jurnal Riset Informatika*, vol. 6, no. 1, Des. 2023.

[14] A. A. Biju (2023, Mar. 27) *Property sales: Melbourne City* [Online]. Available at: https://www.kaggle.com/datasets/amalab182/property-salesmelbourne-city (Accessed: 26 Des 2025).

[15] Google Cloud (2025, Des. 17) *The CREATE MODEL statement for boosted trees models using XGBoost | BigQuery* [Online]. Available at: https://docs.cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-create-boosted-tree (Accessed: 26 Des 2025).

[16] Tim Kelas AI (2025, Jan. 11) Memahami MAE, MSE, RMSE, dan R^2 pada Machine Learning Regresi [Online]. Available at: https://www.kelasai.id/blog/memahami-mae-mse-rmse-dan-r2-pada-machine-learning-regresi (Accessed: 27 Dec 2025).

[17] D4 Manajemen Informatika UNESA (2025, Nov. 17) *Regresi Linear: Pengertian, Rumus, Contoh, dan Cara Menghitung* [Online]. Available at: https://terapan-ti.vokasi.unesa.ac.id/post/regresi-linear-pengertian-rumus-contoh-dan-cara-menghitung (Accessed: 29 Des 2025).

[18] A. Desiani, S. Nurhaliza, T. F. Putri, and B. Suprihatin, "Algoritma Extreme Gradient Boosting (XGBoost) dan Adaptive Boosting (AdaBoost) Untuk Klasifikasi Penyakit Tiroid", *Jurnal Rekayasa Elektro Sriwijaya*, vol. 6, no. 2, Mei 2025.

[19] M. W. Dwinanda, N. Satyahadewi, and W. Andani, "CLASSIFICATION OF STUDENT GRADUATION STATUS USING XGBOOST ALGORITHM," BAREKENG J. Ilmu Mat. dan Terap., vol. 17, no. 3, pp. 1785–1794, Sep. 2023, doi: 10.30598/barekengvol17iss3pp1785-1794.